



PRA-SKRIPSI

**NOWCASTING PROBABILISTIK PRESIPITASI
UNTUK MITIGASI RISIKO PENDAKI DI
GUNUNG GEDE-PANGRANGO
MENGUNAKAN RETRIEVAL-AUGMENTED
DIFFUSION MODEL DENGAN SPATIO-
TEMPORAL GRAPH CONDITIONING**

BEVANTYO SATRIA PINANDHITA
NPM 22081010153

DOSEN PEMBIMBING

Faisal Muttaqin, S.Kom, M.T
Andreas Nugroho Sihananto, S.Kom., M.Kom.

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA
2026**

ABSTRAK

Nama Mahasiswa / NPM : Bevantyo Satria Pinandhita / 22081010153
Judul Skripsi : Nowcasting Probabilistik Presipitasi Untuk Mitigasi Risiko Pendaki di Gunung Gede–Pangrango Menggunakan Retrieval-Augmented Diffusion Model Dengan Spatio-Temporal Graph Conditioning
Dosen Pembimbing : 1. Faisal Muttaqin, S.Kom, M.T
2. Andreas Nugroho Sihananto, S.Kom., M.Kom.

[DRAFT]

Nowcasting cuaca jangka pendek pada skala waktu 0–6 jam memiliki peran penting dalam mitigasi risiko bencana dan keselamatan aktivitas luar ruang, terutama pada wilayah pegunungan dengan dinamika atmosfer yang cepat berubah. Kawasan Gunung Gede–Pangrango merupakan salah satu lokasi pendakian dengan intensitas kunjungan tinggi dan kondisi mikrocuaca yang kompleks, sehingga perubahan presipitasi, angin, dan kelembapan dapat menimbulkan risiko keselamatan bagi pendaki. Namun, pendekatan prakiraan cuaca deterministik konvensional sering kali kurang mampu merepresentasikan ketidakpastian atmosfer serta cenderung mengalami bias terhadap nilai rata-rata, yang menyebabkan keterbatasan dalam mendeteksi kejadian presipitasi ekstrem. Penelitian ini bertujuan mengembangkan model nowcasting presipitasi probabilistik untuk mendukung mitigasi risiko pendakian di kawasan Gunung Gede–Pangrango. Model yang diusulkan menggunakan pendekatan Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning untuk memodelkan hubungan spasial dan temporal antar lokasi pengamatan. Data cuaca diperoleh dari dataset reanalysis ERA5 melalui Open-Meteo API dengan resolusi waktu per jam. Model dilatih untuk menghasilkan distribusi probabilistik kondisi presipitasi satu jam ke depan ($t + 1$), yang berada dalam rentang nowcasting 0–6 jam menurut WMO. Kinerja model dievaluasi menggunakan metrik statistik dan probabilistik serta dibandingkan dengan pendekatan regresi deterministik berbasis machine learning. Hasil penelitian diharapkan dapat memberikan pendekatan nowcasting yang lebih adaptif dalam merepresentasikan ketidakpastian cuaca serta meningkatkan sensitivitas deteksi terhadap kejadian presipitasi yang berpotensi membahayakan aktivitas pendakian.

Kata kunci: Diffusion model, Mitigasi risiko pendakian, Nowcasting cuaca, Presipitasi probabilistik, Spatio-temporal graph

ABSTRACT

Nama Mahasiswa / NPM : Bevantyo Satria Pinandhita / 22081010153
Judul Skripsi : Nowcasting Probabilistik Presipitasi Untuk Mitigasi
Risiko Pendaki di Gunung Gede–Pangrango
Menggunakan Retrieval-Augmented Diffusion
Model Dengan Spatio-Temporal Graph Conditioning
Dosen Pembimbing : 1. Faisal Muttaqin, S.Kom, M.T
2. Andreas Nugroho Sihananto, S.Kom., M.Kom.

[DRAFT]

Short-term weather nowcasting within a 0–6 hour horizon plays a crucial role in disaster risk mitigation and outdoor activity safety, particularly in mountainous regions where atmospheric conditions can change rapidly. The Gunung Gede–Pangrango area is one of the most popular hiking destinations in Indonesia and exhibits complex microclimate dynamics, where variations in precipitation, wind, and humidity may pose significant risks to hikers. Conventional deterministic weather forecasting approaches often fail to adequately represent atmospheric uncertainty and tend to exhibit bias toward mean values, limiting their capability to detect extreme precipitation events. This study aims to develop a probabilistic precipitation nowcasting model to support risk mitigation for hiking activities in the Gunung Gede–Pangrango region. The proposed approach employs a Retrieval-Augmented Diffusion Model combined with Spatio-Temporal Graph Conditioning to capture spatial and temporal dependencies among observation locations. Weather data are obtained from the ERA5 reanalysis dataset through the Open-Meteo API with hourly temporal resolution. The model is trained to generate probabilistic distributions of precipitation conditions one hour ahead ($t+1$), within the WMO nowcasting range of 0–6 hours. Model performance is evaluated using statistical and probabilistic metrics and compared with deterministic machine learning regression approaches. The expected outcome of this research is a more adaptive nowcasting framework capable of representing atmospheric uncertainty while improving sensitivity to precipitation events that may pose hazards for mountain hiking activities.

Keywords: Diffusion model, hiking risk mitigation, probabilistic precipitation, spatio-temporal graph, weather nowcasting

DAFTAR ISI

DAFTAR ISI	iv
DAFTAR GAMBAR	vi
DAFTAR TABEL	vii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	5
1.3 Tujuan Penelitian.....	5
1.4 Manfaat Penelitian.....	6
1.5 Batasan Masalah.....	7
BAB II TINJAUAN PUSTAKA.....	10
2.1 Penelitian Terdahulu.....	10
2.2 Landasan Teori	20
2.2.1 Konsep Nowcasting dan Skala Waktu Prediksi Atmosfer	21
2.2.1.2 Definisi dan Ruang Lingkup Nowcasting	21
2.2.1.3 Karakteristik Dinamika pada Skala Waktu Per Jam di Wilayah Pegunungan.....	22
2.2.1.4 Keterbatasan Pendekatan Deterministik dan Relevansi Pendekatan Probabilistik	23
2.2.2 Dinamika Presipitasi Orografis di Pegunungan Tropis	24
2.2.2.1 Mekanisme Orographic Lifting dan Convective Initiation	25
2.2.2.2 Variabilitas Spasial dan Temporal Presipitasi Orografis.....	26
2.2.2.3 Relevansi dengan Nowcasting Probabilistik dan Mitigasi Risiko..	27
2.2.3 Model Generatif Probabilistik dengan Diffusion Models	27
2.2.3.1 Prinsip Kerja dan Keunggulan Diffusion Models untuk Nowcasting	29
2.2.3.2 Keterbatasan Model Deterministik dan Relevansi Pendekatan Generatif	29
2.2.3.3 Relevansi dengan Retrieval-Augmented Diffusion Model	30
2.2.4 Retrieval-Based Historical Analogs	30
2.2.4.1 Prinsip Kerja Retrieval-Based Historical Analogs	31
2.2.4.2 Keunggulan Retrieval-Augmented dibandingkan Pure Generative Models	32
2.2.5 Spatio-Temporal Graph Conditioning pada Representasi Data Elevasi.....	32
2.2.5.1 Representasi Graph untuk Data Elevasi dengan Lima Node.....	33

2.2.5.2 Keunggulan Spatio-Temporal Graph dibandingkan Pendekatan Konvensional	34
2.2.6 Risiko Hipotermia dan Mitigasi Pendakian.....	35
2.2.6.1 Mekanisme Hipotermia di Lingkungan Pegunungan Tropis.....	36
2.2.6.2 Faktor Meteorologis Pemicu Risiko Hipotermia.....	36
2.2.6.3 Relevansi Nowcasting Probabilistik sebagai Mitigasi Risiko	37
2.3 Analisis Celah Penelitian.....	38
2.3.1.1 Celah pada Representasi Spasial dan Temporal	39
2.3.1.2 Celah pada Penanganan Kejadian Ekstrem dan Ketidakpastian	39
2.3.1.3 Celah pada Aplikasi Mitigasi Risiko Pendakian	39
BAB III METODE PENELITIAN	41
3.1 Pendekatan Penelitian.....	41
3.2 Studi Literatur.....	41
3.3 Tahapan Penelitian	42
3.3.1 Pengambilan Data	44
3.3.2 Preprocessing Data	47
3.3.3 Pembagian Dataset Temporal	50
3.3.4 Pembentukan Fitur dan Representasi Graf	51
3.3.4.1 Pembentukan Fitur Input	51
3.3.4.2 Pembentukan Jendela Waktu (<i>Temporal Window</i>)	52
3.3.4.3 Representasi Graf Spasial.....	52
3.3.4.4 Representasi Spasio-Temporal	53
3.3.5 Perancangan Arsitektur Model	53
3.3.5.1 Spatio-Temporal Graph Neural Network (STGNN)	53
3.3.5.2 Retrieval-Augmented	54
3.3.5.3 Conditional Diffusion Model	54
3.3.5.4 Integrasi Antar Komponen Model.....	55
3.3.6 Prosedur Pelatihan Model.....	55
3.3.7 Prosedur Inferensi	56
3.3.8 Metode Evaluasi Model.....	57
3.3.9 Skenario Eksperimen	59
DAFTAR PUSTAKA	62

DAFTAR GAMBAR

Gambar 3.1	Diagram Alur Tahapan Penelitian	43
Gambar 3.2	Diagram Proses Pengambilan Data ERA5 melalui Open-Meteo API	45
Gambar 3.3	Posisi Lima Node Pengamatan pada Wilayah Studi Gunung Gede– Pangrango	46
Gambar 3.4	Diagram Alur Preprocessing Data.....	48
Gambar 3.5	Ilustrasi Pembagian Dataset Temporal	50

DAFTAR TABEL

Tabel 2.1 Tabel Penelitian Terdahulu.....	18
Tabel 2.2 Perbandingan Skala Prakiraan Atmosfer disusun [5] [17].	21
Tabel 2.3 Perbandingan Keluaran Deterministik dan Probabilistik pada Nowcasting [4], [17], [27].	24
Tabel 2.4 Definisi Node pada Representasi Graph Lima Node [9], [12], [31].....	34
Tabel 2.5 Faktor Meteorologis terkait Paparan Dingin Pendaki [28], [22]	36
Tabel 3.1 Koordinat Node	46
Tabel 3.2 Karakteristik Dataset Penelitian	47
Tabel 3.3 Daftar Fitur Input Model	51
Tabel 3.4 Ringkasan Metrik Evaluasi.....	58

BAB I

PENDAHULUAN

1.1 Latar Belakang

Nowcasting cuaca dalam jangka waktu yang pendek memiliki peran krusial dalam mitigasi risiko bencana, keselamatan aktivitas luar ruang, dan sistem peringatan dini. Skala waktu hourly (per jam) lebih kritis dibandingkan prakiraan harian karena mampu memberikan informasi yang lebih cepat mengenai perubahan kondisi atmosfer yang berlangsung secara dinamis. Dalam konteks ini, informasi mengenai presipitasi probabilistik, yaitu peluang terjadinya presipitasi dalam rentang waktu tertentu, menjadi penting untuk memahami tingkat ketidakpastian kondisi cuaca yang akan terjadi. Pendekatan probabilistik memungkinkan prediksi tidak hanya berupa nilai tunggal, tetapi juga distribusi kemungkinan kejadian presipitasi yang dapat berkaitan dengan potensi hujan intensitas tinggi maupun perubahan kondisi atmosfer lain seperti peningkatan kecepatan angin. Informasi tersebut sangat relevan untuk mendukung pengambilan keputusan yang lebih adaptif dalam menghadapi risiko cuaca ekstrem, seperti banjir dan tanah longsor, terutama pada aktivitas yang sangat bergantung pada kondisi cuaca jangka pendek.

Nowcasting memungkinkan deteksi dini dan respons cepat terhadap kondisi cuaca ekstrem, sehingga dapat mengurangi kerugian jiwa dan materi serta meningkatkan keselamatan masyarakat, terutama dalam kegiatan yang sangat bergantung pada kondisi cuaca seperti pendakian gunung dan aktivitas outdoor lainnya [1], [2]. Sistem peringatan dini yang mengandalkan nowcasting cuaca jangka pendek dapat mengintegrasikan data radar, model numerik, dan kecerdasan buatan untuk menghasilkan prediksi yang lebih tepat dan real-time, mendukung pengambilan keputusan yang cepat dan efektif oleh otoritas dan masyarakat [2], [3]. Penelitian juga menunjukkan bahwa metode nowcasting berbasis radar dan deep learning mampu memberikan prediksi hujan dan angin dengan resolusi spasial dan temporal tinggi, yang sangat penting untuk keselamatan dan mitigasi risiko di area rawan bencana [4], [5], [6].

Kawasan Gunung Gede–Pangrango merupakan salah satu taman nasional dengan intensitas aktivitas wisata dan pendakian yang tinggi, terutama di Resort

Cibodas dan kawasan Curug Cibeureum, sehingga memiliki tingkat paparan risiko lingkungan dan keselamatan yang signifikan. Kajian daya dukung kawasan Curug Cibeureum [7], menunjukkan bahwa angka kunjungan harian pada akhir pekan dan musim liburan telah melampaui real carrying capacity (RCC) dan effective carrying capacity (ECC), meskipun masih berada di bawah physical carrying capacity (PCC), yang mengindikasikan potensi gangguan terhadap kualitas lingkungan dan keselamatan pengunjung. Berbagai faktor biofisik seperti curah hujan tinggi, kemiringan lereng yang curam, erodibilitas tanah, serta sensitivitas ekosistem dan satwa liar diidentifikasi sebagai pembatas utama aktivitas wisata di kawasan ini, dengan curah hujan muncul sebagai faktor koreksi dominan yang secara signifikan menurunkan nilai RCC dan ECC hingga pada periode tertentu memaksa penutupan penuh akses ke Curug Cibeureum demi keselamatan [7]. Temuan tersebut menegaskan bahwa variabilitas cuaca jangka pendek tidak hanya memengaruhi kenyamanan wisata, tetapi juga secara langsung menentukan keputusan manajemen terkait pembatasan/pembukaan jalur, pengaturan jumlah pengunjung, dan mitigasi risiko kecelakaan maupun bencana hidrometeorologis. Dalam konteks ini, ketersediaan informasi cuaca per jam yang akurat dan adaptif menjadi krusial untuk mendukung sistem peringatan dini dan pengambilan keputusan operasional di kawasan pegunungan yang bercirikan dinamika atmosfer cepat dan heterogenitas spasial tinggi [3]. Oleh karena itu, pengembangan pendekatan nowcasting cuaca jangka pendek yang mampu menyajikan informasi probabilistik mengenai hujan, angin, dan kelembapan pada skala lokal menjadi sangat relevan untuk melengkapi strategi pengelolaan berbasis daya dukung dan meningkatkan keselamatan aktivitas pendakian di Gunung Gede–Pangrango [4], [8].

Hujan dalam skala waktu per jam di wilayah pegunungan memiliki karakteristik yang kompleks akibat interaksi dinamis antara hujan, angin, dan kelembapan yang secara bersama-sama dapat memicu risiko hipotermia bagi pendaki dan aktivitas luar ruang lainnya. Wilayah orografis seperti Gunung Gede–Pangrango menunjukkan variabilitas spasial yang sangat tinggi dan dinamika cuaca yang cepat berubah, sehingga prediksi cuaca di area ini menjadi sangat menantang bagi model numerik konvensional. Penelitian di berbagai pegunungan tropis dan subtropis menunjukkan bahwa curah hujan orografis sangat dipengaruhi oleh

mekanisme pengangkatan udara akibat topografi, yang memodulasi suhu dan kelembapan di lapisan troposfer bawah, serta kecepatan dan arah angin yang membawa uap air [9], [10]. Selain itu, variabilitas spasial dan temporal hujan di pegunungan sangat dipengaruhi oleh siklus diurnal dan musiman, di mana puncak hujan sering terjadi pada siang hingga sore hari, terkait dengan pemanasan permukaan dan konveksi lokal [11]. Studi juga menemukan bahwa gradien curah hujan terhadap elevasi dapat sangat bervariasi, dengan korelasi positif antara curah hujan dan kelembapan relatif, serta korelasi negatif dengan kecepatan angin, yang menunjukkan peran penting interaksi antara kelembapan dan angin dalam pembentukan hujan orografis [12], [13]. Oleh karena itu, pemahaman mendalam tentang interaksi hujan, angin, dan kelembapan di wilayah pegunungan sangat penting untuk mengembangkan model nowcasting yang akurat dan andal guna mitigasi risiko hipotermia dan bahaya cuaca ekstrem selama pendakian gunung.

Model deterministik dalam prakiraan cuaca sering gagal merepresentasikan ketidakpastian yang melekat dalam sistem atmosfer, sehingga kurang mampu menangkap variabilitas dan risiko cuaca ekstrem secara akurat. Model regresi berbasis machine learning (ML) cenderung bias ke nilai rata-rata, yang menyebabkan under-prediction pada kejadian ekstrem atau distribusi ekor berat (heavy-tail), sehingga mengurangi keandalan prediksi untuk peristiwa cuaca yang jarang namun berdampak besar. Selain itu, dataset gridded seperti ERA5 yang sering digunakan untuk pelatihan model ML memiliki efek smoothing yang ekstrem, sehingga melemahkan representasi kuantil atas dari variabel cuaca, yang penting untuk memprediksi kejadian ekstrem dengan tepat. Studi menunjukkan bahwa meskipun model ML seperti PanguWeather dan GraphCast menunjukkan akurasi yang kompetitif dengan model numerik fisika, mereka masih kurang dalam reproduksi fenomena mesoskal dan sub-sinoptik serta konsistensi fisik, yang berdampak pada interpretasi dan keandalan prediksi mereka [14], [15]. Pendekatan ML probabilistik terbaru seperti FuXi-ENS [16], mulai mengatasi keterbatasan ini dengan menghasilkan ensemble prediksi yang lebih baik dalam merepresentasikan ketidakpastian dan kejadian ekstrem, namun tantangan dalam resolusi spasial dan representasi fisik masih ada [17]. Oleh karena itu, pengembangan model

nowcasting yang menggabungkan aspek probabilistik dan fisika atmosfer tetap menjadi kebutuhan penting untuk meningkatkan akurasi dan keandalan prakiraan cuaca jangka pendek, terutama di wilayah pegunungan dengan dinamika kompleks.

Meskipun berbagai pendekatan deep learning telah dikembangkan untuk nowcasting curah hujan, sebagian besar studi masih berfokus pada prediksi deterministik atau peringatan berbasis threshold tanpa mengintegrasikan secara simultan model probabilistik generatif, pencarian analog historis berbasis retrieval, dan representasi grafis spatio-temporal. Pendekatan deep generative models telah menunjukkan kemampuan dalam menghasilkan prediksi probabilistik yang realistis dan konsisten secara spasial dan temporal, namun penerapannya masih terbatas pada data radar dan wilayah datar, belum banyak dieksplorasi untuk konteks mikrocuaca di wilayah pegunungan dengan data reanalysis titik-lokasi [4], [5]. Studi lain menggunakan model deep learning seperti LSTM dan ConvLSTM untuk prediksi curah hujan di pegunungan, tetapi masih menghadapi tantangan dalam menangani variabilitas spasial tinggi dan dinamika cepat yang khas di wilayah orografis [8], [18], [19]. Selain itu, integrasi data multi-sumber dan teknik representasi grafis untuk menangkap hubungan spasial dan temporal secara simultan masih jarang diterapkan dalam nowcasting curah hujan di pegunungan, padahal hal ini penting untuk meningkatkan akurasi dan ketahanan model terhadap ketidakpastian [20], [21]. Pendekatan hybrid yang menggabungkan model fisika dan deep learning mulai menunjukkan hasil yang menjanjikan, tetapi belum menggabungkan aspek probabilistik dan retrieval historis secara komprehensif [20]. Oleh karena itu, terdapat gap riset yang signifikan dalam mengembangkan model nowcasting curah hujan yang mengintegrasikan probabilistic generative modeling, retrieval-based historical analogs, dan spatio-temporal graph representation secara bersamaan untuk konteks mikrocuaca pegunungan berbasis data reanalysis titik-lokasi.

Penelitian ini mengevaluasi model nowcasting curah hujan yang mengintegrasikan probabilistic generative modeling, retrieval-based historical analogs, dan spatio-temporal graph representation secara simultan untuk konteks

mikrocuaca Gunung Gede–Pangrango. Studi ini berorientasi pada mitigasi risiko pendakian dengan menelaah trade-off antara akurasi prediksi dan sensitivitas terhadap kejadian ekstrem. Pendekatan ini relevan untuk menilai kegunaan prediksi probabilistik sebagai informasi pendukung pengambilan keputusan sebelum dan selama pendakian [22], [23], [24], [25].

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan penelitian ini dapat dirumuskan sebagai berikut:

1. Bagaimana kinerja pendekatan nowcasting probabilistik berbasis probabilistic generative modeling dalam memprediksi dinamika hujan, angin, dan kelembapan pada skala waktu per jam di wilayah pegunungan Gunung Gede–Pangrango berbasis data reanalysis titik-lokasi?
2. Sejauh mana integrasi retrieval-based historical analogs dan spatio-temporal graph representation mampu meningkatkan kemampuan model dalam menangkap ketidakpastian serta dinamika spasial-temporal mikrocuaca di wilayah pegunungan?
3. Bagaimana kemampuan model probabilistik dalam memberikan estimasi ketidakpastian prakiraan cuaca multi-variabel melalui kerangka ensemble nowcasting?
4. Bagaimana trade-off antara akurasi prediksi rata-rata dan sensitivitas terhadap kejadian ekstrem pada konteks aplikasi mitigasi risiko pendakian di wilayah pegunungan?
5. Bagaimana hasil prediksi nowcasting probabilistik dapat disiapkan sebagai keluaran untuk sistem visualisasi berbasis web dalam mendukung pengambilan keputusan aktivitas pendakian di wilayah pegunungan?

1.3 Tujuan Penelitian

Tujuan umum dari penelitian ini adalah mengevaluasi kemampuan pendekatan nowcasting probabilistik berbasis probabilistic generative modeling yang terintegrasi dengan retrieval-based historical analogs dan spatio-temporal graph representation dalam memprediksi dinamika hujan, angin, dan kelembapan

pada skala waktu per jam di wilayah pegunungan Gunung Gede–Pangrango untuk mendukung mitigasi risiko pendakian.

Untuk mencapai tujuan umum tersebut, penelitian ini memiliki tujuan khusus sebagai berikut:

1. Menganalisis kinerja model nowcasting probabilistik berbasis probabilistic generative modeling dalam memprediksi hujan, angin, dan kelembapan pada skala waktu per jam di wilayah pegunungan berbasis data reanalysis titik-lokasi.
2. Mengevaluasi kontribusi integrasi retrieval-based historical analogs dan spatio-temporal graph representation terhadap kemampuan model dalam menangkap ketidakpastian serta dinamika spasial-temporal mikrocuaca di wilayah pegunungan.
3. Membandingkan kemampuan model probabilistik dengan pendekatan regresi deterministik berbasis machine learning konvensional dalam mendeteksi kejadian cuaca ekstrem, khususnya pada distribusi curah hujan yang bersifat heavy-tailed.
4. Menganalisis trade-off antara akurasi prediksi rata-rata dan sensitivitas terhadap kejadian ekstrem dalam konteks aplikasi mitigasi risiko pendakian di wilayah pegunungan.
5. Menyajikan hasil prediksi nowcasting probabilistik sebagai artefak evaluasi yang dapat menjadi dasar pengembangan sistem visualisasi berbasis web untuk mitigasi risiko pendakian.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan metode nowcasting cuaca serta penerapannya dalam mendukung mitigasi risiko aktivitas pendakian di wilayah pegunungan. Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi dalam pengembangan dan evaluasi pendekatan nowcasting probabilistik berbasis probabilistic generative modeling untuk memodelkan dinamika hujan, angin, dan kelembapan pada skala waktu per jam di wilayah pegunungan.
2. Menyediakan pemahaman yang lebih komprehensif mengenai efektivitas integrasi retrieval-based historical analogs dan spatio-temporal graph

representation dalam menangkap ketidakpastian serta hubungan spasial-temporal mikrocuaca.

3. Memberikan gambaran empiris mengenai perbandingan kinerja antara model probabilistik dan pendekatan regresi deterministik berbasis machine learning dalam mendeteksi kejadian cuaca ekstrem, khususnya pada distribusi presipitasi yang bersifat heavy-tailed.
4. Menyediakan analisis terkait trade-off antara akurasi prediksi rata-rata dan sensitivitas terhadap kejadian ekstrem sebagai dasar dalam pengambilan keputusan berbasis risiko pada aktivitas pendakian di wilayah pegunungan.
5. Menyediakan keluaran prediksi probabilistik yang dapat digunakan sebagai dasar pengembangan sistem visualisasi berbasis web untuk penyampaian informasi cuaca jangka pendek.

1.5 Batasan Masalah

Untuk menjaga fokus penelitian dan memastikan ketercapaian tujuan dalam ruang lingkup skripsi, penelitian ini dibatasi oleh beberapa ketentuan sebagai berikut:

1. Wilayah kajian dibatasi pada kawasan Gunung Gede–Pangrango yang direpresentasikan oleh 5 titik lokasi (node) yang berbeda. Pembatasan ini dilakukan untuk merepresentasikan gradasi orografis utama secara sederhana namun relevan, sekaligus menjaga kompleksitas model dan ketersediaan data agar tetap seimbang.
2. Model menggunakan jendela observasi 6 jam terakhir sebagai input untuk memprediksi kondisi cuaca satu jam ke depan (single-step hourly nowcasting). Pendekatan ini sesuai dengan definisi nowcasting menurut WMO, yaitu prakiraan dengan rentang waktu 0–6 jam, di mana model dijalankan secara iteratif pada setiap jam. Batasan ini dipilih karena perubahan cuaca yang berisiko tinggi terhadap keselamatan pendakian umumnya terjadi dalam rentang waktu singkat, sehingga informasi prediksi per jam lebih relevan dibandingkan prakiraan harian.
3. Variabel cuaca yang diprediksi dibatasi pada curah hujan, kecepatan angin, dan kelembapan relatif. Ketiga variabel tersebut dipilih karena relevan terhadap bahaya cuaca selama pendakian. Suhu udara tetap digunakan sebagai fitur input,

tetapi tidak menjadi target agar fokus model tetap pada tiga variabel keluaran dan kompleksitas pelatihan tidak bertambah.

4. Sumber data cuaca dibatasi pada dataset reanalysis ERA5 yang diperoleh melalui Open-Meteo API dengan resolusi spasial grid dan resolusi temporal per jam. Dataset ini dipilih karena ketersediaannya yang konsisten dalam jangka panjang serta cakupan historis yang memadai untuk pelatihan model, meskipun memiliki keterbatasan dalam merepresentasikan kejadian ekstrem berskala kecil.
5. Penelitian ini tidak menggunakan data radar cuaca, satelit resolusi tinggi, maupun observasi stasiun hujan lokal sebagai sumber data utama. Pembatasan ini dilakukan untuk memfokuskan penelitian pada evaluasi pendekatan metodologis berbasis machine learning probabilistik terhadap data reanalysis titik-lokasi, serta menghindari ketergantungan pada data yang tidak selalu tersedia secara operasional di wilayah pegunungan.
6. Pendekatan pemodelan dibatasi pada evaluasi model probabilistik berbasis probabilistic generative modeling yang terintegrasi dengan retrieval-based historical analogs dan spatio-temporal graph representation. Penelitian ini tidak bertujuan untuk melakukan eksplorasi menyeluruh terhadap seluruh arsitektur deep learning yang tersedia, melainkan mengevaluasi pendekatan yang telah ditentukan secara konseptual sesuai dengan tujuan penelitian.
7. Evaluasi kinerja model difokuskan pada metrik probabilistik dan metrik akurasi statistik, serta analisis sensitivitas terhadap kejadian ekstrem. Evaluasi tidak mencakup implementasi sistem peringatan dini operasional, indeks risiko hipotermia, sistem visualisasi web, maupun pengujian langsung di lapangan; keluaran tersebut merupakan arah pengembangan lanjutan. Sistem visualisasi yang direncanakan adalah dashboard web dengan Vue.js pada frontend dan FastAPI pada backend, tetapi belum diimplementasikan dalam pipeline penelitian ini.
8. Data presipitasi bersifat zero-inflated dan heavy-tailed sehingga kejadian ekstrem langka. Penanganan melalui transformasi $\log_{1p}$, weighted denoising loss, retrieval analog historis, dan ensemble diffusion tidak menjamin deteksi kejadian ekstrem; keterbatasan ini dianalisis secara eksplisit pada metrik berbasis ambang.

9. ERA5 merupakan data reanalysis historis dengan latensi sekitar 5–7 hari, sehingga tidak digunakan sebagai sumber operasional real-time. Penerapan operasional memerlukan penggantian sumber data dengan radar, stasiun cuaca otomatis, atau satelit near real-time.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian-penelitian yang sudah dilakukan peneliti sebelumnya yang terkait dengan penelitian yang akan dilakukan adalah sebagai berikut.

1. Penelitian “Training of AI-based Nowcasting Models for Rainfall Early Warning Should Take into Account User Requirements” oleh Ayzel dan Heistermann (2025) [26].

Penelitian oleh Ayzel dan Heistermann mengkaji keterbatasan fundamental model nowcasting berbasis deep learning dalam mendukung sistem peringatan dini, khususnya dalam memprediksi presipitasi ekstrem. Studi ini berangkat dari observasi bahwa meskipun model deep learning mampu menangkap pola kompleks dari data radar, performanya menurun signifikan pada kejadian hujan lebat yang justru paling krusial secara operasional. Penulis mengusulkan bahwa akar permasalahan bukan semata pada arsitektur model, melainkan pada ketidaksesuaian antara tujuan pelatihan (training objective) dan kebutuhan pengguna. Untuk menguji hipotesis ini, mereka mengubah formulasi masalah dari regresi kontinu menjadi prediksi berbasis threshold (segmentation), serta dari resolusi temporal tinggi (5 menit) menjadi akumulasi curah hujan per jam yang lebih relevan dengan sistem peringatan. Hasil eksperimen menunjukkan bahwa model berbasis threshold (RainNet2024-S) secara konsisten mengungguli model regresi dalam mendeteksi kejadian hujan ekstrem, terutama pada metrik CSI dan FSS, meskipun secara umum semua model masih menunjukkan skill yang terbatas pada intensitas tinggi. Temuan ini menegaskan bahwa penyederhanaan target prediksi yang selaras dengan kebutuhan pengguna dapat meningkatkan performa operasional model tanpa harus meningkatkan kompleksitas arsitektur. Namun demikian, penelitian ini masih terbatas pada pendekatan deterministik berbasis threshold dan belum mengakomodasi representasi distribusi probabilistik secara eksplisit, sehingga kemampuan untuk mengkuantifikasi ketidakpastian dan mengevaluasi risiko tetap terbatas. Selain itu, ketergantungan pada data radar resolusi tinggi membatasi generalisasi ke konteks dengan keterbatasan data.

2. Penelitian “Precipitation Nowcasting with Generative Diffusion Models” oleh Asperti et al. (2023) [27].

Penelitian oleh Asperti et al. mengusulkan pendekatan baru untuk nowcasting curah hujan berbasis *generative diffusion models*, dengan argumen bahwa pendekatan probabilistik lebih sesuai dibandingkan model deterministik dalam menangani sifat stokastik atmosfer. Berbeda dengan model konvensional yang dioptimalkan menggunakan *mean squared error* dan cenderung menghasilkan prediksi yang “blur” akibat averaging, diffusion model secara eksplisit memodelkan distribusi probabilitas curah hujan melalui proses denoising bertahap dari noise menjadi kondisi atmosfer yang realistis. Kontribusi utama penelitian ini adalah pengembangan *Generative Ensemble Diffusion (GED)*, yaitu pendekatan yang menghasilkan multiple skenario prediksi (ensemble) dan menggabungkannya melalui rata-rata atau *post-processing U-Net* untuk meningkatkan akurasi. Hasil eksperimen pada dataset ERA5 menunjukkan bahwa meskipun single diffusion model masih kalah dibandingkan model U-Net konvensional, pendekatan ensemble GED secara konsisten mengungguli semua baseline, terutama pada metrik MSE dan recall untuk prediksi hingga 3 jam ke depan. Selain itu, hasil dari penelitian ini menunjukkan performa yang meningkat signifikan ketika menggunakan post-processing dibanding sekadar averaging. Namun, penelitian ini memiliki beberapa keterbatasan penting: ketergantungan pada banyak sampling (hingga 15 generasi) meningkatkan biaya komputasi dan latency, yang berpotensi menghambat implementasi real-time; selain itu, evaluasi masih berfokus pada MSE yang kurang sensitif terhadap kejadian ekstrem. Secara konseptual, meskipun diffusion model menawarkan keunggulan dalam representasi ketidakpastian, pendekatan ini masih belum sepenuhnya menyelesaikan trade-off antara akurasi, efisiensi, dan interpretabilitas dalam sistem nowcasting operasional.

3. Penelitian “On Some Limitations of Current Machine Learning Weather Prediction Models” oleh Bonavita (2024) [14].

Penelitian oleh Bonavita (2024) secara kritis mengevaluasi keterbatasan model prediksi cuaca berbasis machine learning (MLWP) seperti Pangu-

Weather, FourCastNet, dan GraphCast, dengan menyoroti bahwa klaim superioritas terhadap model fisika tradisional perlu ditinjau ulang dari perspektif konsistensi fisik. Meskipun model-model ini menunjukkan performa kompetitif pada metrik deterministik dan memiliki efisiensi komputasi yang jauh lebih tinggi, analisis spektral menunjukkan bahwa prediksi ML cenderung kehilangan energi pada skala spasial kecil, menghasilkan output yang terlalu halus (*over-smoothing*) dan gagal merepresentasikan fenomena mesoskal seperti siklon tropis secara akurat. Lebih jauh, evaluasi keseimbangan fisik mengungkap inkonsistensi mendasar, termasuk pelemahan hubungan geostrofik antara angin dan geopotensial, penurunan komponen divergen aliran, serta estimasi gerakan vertikal yang secara signifikan lebih lemah hingga 40–50% lebih kecil dibanding model fisika, yang berdampak langsung pada ketidakakuratan prediksi fenomena cuaca aktif seperti presipitasi. Selain itu, seperti ditunjukkan dalam analisis spektrum dan error growth, model ML tidak mampu mereproduksi dinamika pertumbuhan error nonlinier (*butterfly effect*), sehingga lebih menyerupai estimator rata-rata distribusi daripada simulator atmosfer yang sebenarnya. Implikasi utamanya adalah bahwa performa tinggi pada metrik seperti MSE dapat bersifat menyesatkan karena dipengaruhi oleh rendahnya variabilitas prediksi. Secara konseptual, penelitian ini menegaskan bahwa *Machine Learning Weather Prediction* (MLWP) saat ini lebih tepat diposisikan sebagai alat *post-processing* daripada pengganti model fisika, serta menyoroti tantangan fundamental dalam mencapai keseimbangan antara akurasi prediksi dan konsistensi dinamika atmosfer.

4. Penelitian “Skilful Nowcasting of Extreme Precipitation with NowcastNet” oleh Zhang et al (2024) [5].

Penelitian oleh Zhang et al. mengembangkan NowcastNet, sebuah model nowcasting presipitasi ekstrem yang mengintegrasikan pendekatan berbasis fisika dan deep learning dalam kerangka generatif bersyarat untuk mengatasi keterbatasan metode sebelumnya yang cenderung menghasilkan prediksi blur, kehilangan intensitas, atau error lokasi. Berbeda dengan pendekatan advection tradisional yang hanya akurat hingga sekitar 1 jam dan model deep learning murni yang sering melanggar prinsip fisika, NowcastNet menggabungkan dua

komponen utama yaitu evolution network berbasis hukum kontinuitas atmosfer dan generative network berbasis latent stochastic sampling untuk menangkap dinamika multiskala dari proses presipitasi. Model ini mampu menghasilkan prediksi hingga 3 jam ke depan dengan resolusi tinggi serta mempertahankan struktur mesoskal dan detail konvektif secara simultan. Evaluasi kuantitatif menggunakan metrik CSI menunjukkan peningkatan signifikan terutama pada intensitas hujan tinggi di atas 16 mm/jam, sementara analisis spektral menunjukkan kemampuan mempertahankan variabilitas spasial yang lebih realistis dibandingkan baseline seperti DGMR, PredRNN, dan pySTEPS. Selain itu, evaluasi oleh 62 meteorolog profesional menunjukkan bahwa NowcastNet dipilih sebagai model terbaik pada sekitar 67–76% kasus, menegaskan nilai operasionalnya dalam konteks prakiraan cuaca ekstrem. Namun demikian, model ini masih sangat bergantung pada data radar resolusi tinggi dan belum secara eksplisit mengeksplorasi distribusi probabilitas untuk analisis risiko atau aplikasi berbasis ketidakpastian, sehingga membuka ruang penelitian lanjutan pada integrasi probabilistik dan adaptasi pada data dengan keterbatasan resolusi seperti reanalysis.

5. Penelitian “A Hybrid Approach to Physical and Deep Learning Models for Radar-Based Precipitation Nowcasting” Oleh Kim et al (2025) [20].

Penelitian oleh Kim et al. mengusulkan pendekatan hybrid nowcasting presipitasi berbasis radar dengan menggabungkan model fisik dan deep learning menggunakan algoritma boosting untuk meningkatkan akurasi prediksi curah hujan jangka pendek. Model ini mengintegrasikan PySTEPS (semi-Lagrangian berbasis adveksi) yang unggul dalam mempertahankan intensitas hujan, serta RainNet (arsitektur U-Net berbasis CNN) yang efektif dalam menangkap pola spasial hujan, kemudian mengombinasikan keduanya menggunakan LightGBM sebagai boosting ensemble yang secara iteratif memperbaiki bias prediksi. Pipeline penelitian dimulai dari prediksi masing-masing model, dilanjutkan dengan proses blending berbasis fitur piksel hujan sebelum menghasilkan prediksi akhir. Dataset radar Korea Selatan (2016–2021) dengan resolusi 1 km dan interval 10 menit digunakan untuk pelatihan dan evaluasi. Hasil eksperimen menunjukkan bahwa model hybrid secara konsisten mengungguli model tunggal

pada berbagai metrik seperti CSI, POD, FAR, RMSE, dan FSS hingga lead time 90 menit, dengan peningkatan CSI sekitar 10–13% pada ambang intensitas 0.1–1 mm/jam. Hasil dari penelitian ini menunjukkan bahwa LightGBM mampu mempertahankan struktur spasial dari RainNet sekaligus intensitas hujan dari PySTEPS. Namun, performa menurun pada hujan intensitas tinggi (>5 mm/jam) untuk lead time panjang, serta masih bergantung pada kualitas data radar resolusi tinggi. Secara keseluruhan, pendekatan blending ini menunjukkan bahwa integrasi model fisik dan data-driven memberikan trade-off optimal antara akurasi spasial dan intensitas, serta menjadi arah menjanjikan untuk sistem prediksi banjir berbasis nowcasting.

6. Penelitian “Predicting rainfall using machine learning, deep learning, and time series models across an altitudinal gradient in the North-Western Himalayas” oleh Wani et al (2024) [18].

Penelitian oleh Wani et al. mengkaji prediksi curah hujan di wilayah Himalaya Barat Laut dengan membandingkan tiga pendekatan utama, yaitu machine learning (ML), deep learning (DL), dan model time series, menggunakan data meteorologi selama 40 tahun (1980–2021) dari enam stasiun dengan variasi ketinggian. Variabel input meliputi suhu maksimum/minimum dan faktor meteorologi lain, dengan proses preprocessing mencakup penanganan missing value dan pembagian data 80:20 untuk training-testing. Model yang diuji meliputi RF, SVR, ANN (ML); RNN, LSTM, GRU, Bi-LSTM (DL); serta ARIMA dan TBATS (time series). Berdasarkan hasil evaluasi menggunakan RMSE dan MAE, model DL secara konsisten menunjukkan performa terbaik, dengan urutan akurasi tertinggi adalah Bi-LSTM, LSTM, RNN, Deep LSTM, dan GRU, sementara ML berada di bawahnya dengan ANN sebagai yang terbaik dan time series menjadi yang terendah. Penelitian ini juga menunjukkan DL mampu menangkap pola non-linear dan dependensi temporal yang kompleks. Selain itu, studi ini menyoroti bahwa ketinggian (*altitude*) secara signifikan mempengaruhi akurasi model, karena variasi topografi menyebabkan heterogenitas pola curah hujan. Namun, penelitian ini tidak mengusulkan model baru, melainkan menunjukkan bahwa pemilihan model yang tepat dan

ketersediaan data berkualitas tinggi menjadi faktor utama dalam meningkatkan akurasi prediksi, terutama di wilayah dengan kompleksitas geografis tinggi.

7. Penelitian “The spatiotemporal variability in precipitation gradients based on meteorological station observations in mountainous areas of Northwest China” oleh Zhang et al (2023) [12].

Penelitian oleh Zhang et al menganalisis variabilitas spasio-temporal curah hujan dan gradien presipitasi (precipitation gradient/PG) di wilayah pegunungan Tianshan dan Qilian menggunakan data stasiun meteorologi periode 1961–2017. Hasil pada penelitian ini menunjukkan bahwa curah hujan di kedua wilayah mengalami tren peningkatan signifikan dalam beberapa dekade terakhir, dengan pola distribusi yang sangat dipengaruhi oleh topografi. Di Tianshan, curah hujan lebih tinggi di bagian utara dan barat, sedangkan di Qilian lebih tinggi di bagian timur. Penelitian ini juga menemukan adanya ketinggian maksimum presipitasi (maximum precipitation height) sekitar 1942,5 m di Tianshan dan sekitar 2850 m di Qilian, yang menunjukkan hubungan non-linear antara elevasi dan curah hujan. Selain itu, gradien presipitasi menunjukkan peningkatan signifikan secara temporal, terutama setelah periode perubahan abrupt pada sekitar tahun 1970–1980-an, yang mengindikasikan tren “humidifikasi” di wilayah pegunungan tersebut. Secara musiman, hubungan antara elevasi dan curah hujan paling kuat terjadi pada bulan Juni–Agustus, sedangkan pada musim dingin hubungan tersebut dapat melemah atau bahkan berbalik. Penelitian ini juga menjelaskan bahwa kelembapan relatif memiliki korelasi positif terhadap PG, sementara kecepatan angin cenderung berkorelasi negatif, menunjukkan interaksi kompleks antara faktor atmosfer dan topografi dalam pembentukan presipitasi. Secara metodologis, pendekatan regresi linear digunakan untuk mengestimasi PG, serta uji Mann-Kendall untuk mendeteksi tren dan perubahan abrupt. Temuan ini menegaskan bahwa distribusi curah hujan di wilayah pegunungan tidak hanya bergantung pada elevasi, tetapi juga pada dinamika atmosfer regional dan interaksi orografis, sehingga memiliki implikasi penting dalam pemodelan hidrologi dan analisis iklim di daerah dengan topografi kompleks.

8. Penelitian “Skilful precipitation nowcasting using deep generative models of radar” oleh Ravuri et al. (2021) [4].

Penelitian ini mengembangkan pendekatan nowcasting curah hujan berbasis deep learning menggunakan model generatif probabilistik dari data radar untuk prediksi jangka sangat pendek (0–90 menit). Permasalahan utama dalam nowcasting konvensional adalah ketergantungan pada metode adveksi berbasis radar yang sulit menangkap fenomena non-linear seperti konveksi, serta keterbatasan model deep learning sebelumnya yang menghasilkan prediksi kabur (blurry) pada lead time panjang. Untuk mengatasi hal tersebut, penelitian ini mengusulkan Deep Generative Model of Radar (DGMR) berbasis conditional Generative Adversarial Network (GAN) yang mampu menghasilkan prediksi probabilistik dengan mempertahankan konsistensi spasial dan temporal. Model menggunakan empat citra radar sebelumnya (20 menit terakhir) sebagai input dan menghasilkan hingga 18 frame prediksi (90 menit ke depan). Berdasarkan evaluasi kuantitatif seperti Critical Success Index (CSI), Continuous Ranked Probability Score (CRPS), serta analisis spektral, model DGMR menunjukkan performa lebih baik dibanding metode baseline seperti PySTEPS dan UNet, terutama dalam mempertahankan struktur curah hujan skala kecil dan intensitas tinggi. Selain itu, berdasarkan studi evaluasi oleh lebih dari 50 meteorolog profesional, model ini dipilih sebagai metode terbaik pada sekitar 89–93% kasus, menunjukkan peningkatan signifikan dalam nilai operasional dan pengambilan keputusan. Penelitian ini menunjukkan bahwa model menggabungkan generator, spatial discriminator, dan temporal discriminator untuk menjaga kualitas prediksi. Meskipun demikian, tantangan masih ada dalam memprediksi curah hujan intensitas tinggi pada lead time panjang. Penelitian ini menegaskan bahwa pendekatan generatif berbasis deep learning memiliki potensi besar dalam meningkatkan akurasi dan utilitas nowcasting dibanding metode tradisional.

9. Penelitian “FuXi-ENS: A machine learning model for efficient and accurate ensemble weather prediction” oleh Zhong et al. (2025) [16].

Penelitian ini mengembangkan model prediksi cuaca berbasis machine learning yang dirancang khusus untuk ensemble forecasting guna mengatasi keterbatasan metode Numerical Weather Prediction (NWP) konvensional dalam

menangani ketidakpastian dan kebutuhan komputasi tinggi. Permasalahan utama pada sistem ensemble tradisional adalah keterbatasan jumlah anggota ensemble akibat biaya komputasi, sehingga distribusi probabilitas kondisi cuaca tidak dapat direpresentasikan secara optimal. Untuk mengatasi hal tersebut, penelitian ini mengusulkan FuXi-ENS, sebuah model berbasis variational autoencoder (VAE) yang mampu menghasilkan prediksi ensemble global hingga 15 hari ke depan dengan resolusi spasial 0.25° . Model ini menggunakan fungsi loss kombinasi antara Continuous Ranked Probability Score (CRPS) dan Kullback-Leibler (KL) divergence untuk menghasilkan perturbasi yang bergantung pada kondisi atmosfer (flow-dependent perturbations), sehingga mampu merepresentasikan ketidakpastian secara lebih realistis dibanding pendekatan deterministik. Berdasarkan hasil evaluasi terhadap berbagai metrik seperti RMSE, Anomaly Correlation Coefficient (ACC), CRPS, dan Brier Score, FuXi-ENS menunjukkan performa yang lebih baik dibandingkan sistem ensemble ECMWF, khususnya pada lead time pendek hingga menengah. Dalam penelitian ini terlihat bahwa FuXi-ENS memiliki RMSE yang lebih rendah dan ACC yang lebih tinggi dibanding ECMWF-ENS, terutama pada variabel suhu permukaan (T2M). Selain itu, model ini juga menunjukkan keunggulan dalam prediksi kejadian ekstrem seperti siklon tropis dan gelombang panas, dengan peningkatan akurasi hingga 10–25% pada beberapa kasus. Dari sisi efisiensi, model ini sangat signifikan karena mampu menghasilkan prediksi 15 hari hanya dalam sekitar 10 detik per anggota ensemble menggunakan GPU, jauh lebih cepat dibanding metode NWP tradisional. Meskipun demikian, model ini masih memiliki keterbatasan dalam estimasi spread ensemble yang cenderung underdispersed, terutama pada lead time awal. Penelitian ini menunjukkan bahwa pendekatan machine learning berbasis probabilistik memiliki potensi besar untuk menggantikan atau melengkapi sistem prediksi cuaca konvensional dalam skala global.

10. Penelitian “Deep Learning Model for Precipitation Nowcasting Based on Residual and Attention Mechanisms” oleh Zhang et al. (2025) [21].

Penelitian ini mengusulkan model deep learning bernama RA-UNet untuk meningkatkan akurasi prediksi curah hujan jangka pendek (nowcasting) berbasis

data radar. Permasalahan utama yang diangkat adalah keterbatasan metode tradisional seperti optical flow dalam menangkap dinamika pembentukan dan peluruhan hujan, serta kelemahan model deep learning sebelumnya seperti U-Net yang cenderung menghasilkan prediksi yang kabur (blur) dan kurang akurat dalam merepresentasikan intensitas hujan ekstrem. Untuk mengatasi hal tersebut, RA-UNet dikembangkan dengan mengintegrasikan arsitektur U-Net dengan residual network (ResNet) dan convolutional block attention module (CBAM), sehingga mampu menangkap fitur spasial dan temporal secara lebih efektif. Selain itu, model ini menggunakan depthwise separable convolution untuk meningkatkan efisiensi komputasi tanpa mengorbankan performa. Model dilatih menggunakan data radar reflectivity dari jaringan CINRAD di China dengan resolusi temporal 6 menit dan total sekitar 37.000 citra radar. Berdasarkan hasil evaluasi, RA-UNet menunjukkan peningkatan performa yang signifikan dibandingkan model pembanding, dengan penurunan Mean Absolute Error (MAE) sekitar 7% dan penurunan False Alarm Ratio (FAR) hingga 20%. Penelitian ini menunjukkan bahwa RA-UNet secara konsisten memiliki nilai MAE lebih rendah dan SSIM lebih tinggi dibanding U-Net dan optical flow pada berbagai lead time. Selain itu, model ini juga mampu mempertahankan struktur spasial curah hujan dan lebih akurat dalam memprediksi area hujan lebat (>40 dBZ), meskipun masih cenderung meremehkan intensitas ekstrem (>50 dBZ). Secara keseluruhan, penelitian ini menunjukkan bahwa kombinasi residual learning dan attention mechanism mampu meningkatkan kemampuan model dalam menangkap dinamika kompleks sistem presipitasi, terutama untuk prediksi jangka pendek hingga 3 jam ke depan.

Tabel 2.1 Tabel Penelitian Terdahulu

No	Judul	Metode	Hasil	Keterangan
1	Precipitation Nowcasting with Generative Diffusion Models [27]	Generative Ensemble Diffusion (GED) berbasis Diffusion Models dengan post-processing U-Net menggunakan dataset ERA5.	Pendekatan ensemble GED secara konsisten mengungguli baseline pada metrik MSE dan recall untuk prediksi hingga 3 jam.	Pendekatan generatif probabilistik untuk nowcasting presipitasi kurang sensitif terhadap ekstrem.

No	Judul	Metode	Hasil	Keterangan
2	Skilful Nowcasting of Extreme Precipitation with NowcastNet [5]	Integrasi evolution network berbasis fisika dan generative network berbasis latent stochastic sampling dalam kerangka generatif bersyarat.	Peningkatan signifikan pada intensitas hujan > 16 mm/jam; dipilih sebagai model terbaik oleh 67–76% meteorolog profesional dibanding baseline.	Model hybrid untuk nowcasting presipitasi ekstrem
3	FuXi-ENS: A machine learning model for efficient and accurate ensemble weather prediction [16]	Ensemble weather prediction berbasis Variational Autoencoder (VAE) dengan fungsi loss CRPS dan KL divergence.	Mengungguli sistem ensemble ECMWF pada lead time pendek-menengah dengan peningkatan akurasi 10–25% pada kejadian ekstrem seperti siklon.	Pendekatan ensemble probabilistik berbasis machine learning
4	Nowcasting Probabilistik Presipitasi Untuk Mitigasi Risiko Pendaki di Gunung Gede–Pangrango Menggunakan Retrieval-Augmented Diffusion Model Dengan Spatio-Temporal Graph Conditioning	Retrieval-Augmented Diffusion Model terintegrasi dengan Spatio-Temporal Graph Conditioning (Graph Attention Network)	-	Penelitian Saat Ini

Berdasarkan Tabel 2.2, ketiga penelitian tersebut menunjukkan kemajuan penting dalam peramalan cuaca berbasis machine learning probabilistik. FuXi-ENS [16] menekankan efisiensi dan akurasi ensemble prediction, Asperti et al. (2023) [27] mengembangkan generative diffusion models untuk nowcasting presipitasi, sedangkan Zhang et al. (2023) [5] fokus pada nowcasting presipitasi ekstrem dengan pendekatan hybrid generatif. Meskipun ketiganya memberikan kontribusi signifikan, penelitian tersebut masih terbatas pada data radar resolusi tinggi atau wilayah non-pegunungan, serta belum mengintegrasikan retrieval-based historical analogs dan spatio-temporal graph conditioning secara simultan dalam konteks mikrocuaca pegunungan tropis. Penelitian ini mengevaluasi kombinasi tersebut untuk konteks data reanalysis titik-lokasi di Gunung Gede–Pangrango.

2.2 Landasan Teori

Landasan teori dalam penelitian ini disusun untuk memberikan fondasi ilmiah bagi pengembangan model nowcasting probabilistik presipitasi menggunakan Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning. Bab ini membahas konsep-konsep utama yang menjadi dasar penelitian, mulai dari prinsip nowcasting pada skala waktu jam-an, dinamika presipitasi orografis di pegunungan tropis, hingga mekanisme model generatif probabilistik berbasis diffusion. Selanjutnya, dijelaskan pula pendekatan retrieval-based historical analogs dan Spatio-Temporal Graph Conditioning dengan representasi lima node yang dirancang untuk menangkap ketergantungan spasial multidirectional di sekitar titik prediksi utama. Pembahasan ditutup dengan analisis risiko hipotermia pada aktivitas pendakian di Gunung Gede–Pangrango serta relevansinya dengan sistem peringatan dini berbasis nowcasting probabilistik. Dengan landasan teori yang terfokus ini, penelitian diharapkan mampu menghasilkan model yang tidak hanya unggul secara teknis, tetapi juga memberikan kontribusi nyata dalam mitigasi risiko keselamatan pendaki di kawasan pegunungan tropis.

2.2.1 Konsep Nowcasting dan Skala Waktu Prediksi Atmosfer

Nowcasting merupakan salah satu bidang paling dinamis dalam ilmu prakiraan cuaca modern karena beroperasi pada batas prediktabilitas atmosfer yang paling sensitif terhadap kondisi awal [4]. Pada skala waktu sangat pendek, atmosfer tidak lagi sepenuhnya didominasi oleh dinamika sinoptik berskala besar, melainkan juga belum sepenuhnya stabil dalam rezim statistik jangka menengah. Posisi antara dua rezim ini menjadikan nowcasting sebagai domain yang memerlukan pendekatan khusus dibandingkan prakiraan harian atau mingguan. Dalam konteks penelitian ini yang berfokus pada mitigasi risiko pendakian di wilayah pegunungan tropis, pemahaman konseptual mengenai nowcasting skala waktu per jam menjadi landasan teoritis yang krusial [5].

Tabel 2.2 Perbandingan Skala Prakiraan Atmosfer disusun [5] [17].

Skala Prakiraan	Horizon	Karakteristik Utama	Contoh Keluaran
Nowcasting	0–6 jam	Bergantung kuat pada kondisi awal dan observasi terkini; menargetkan fenomena lokal yang berubah cepat.	Prediksi presipitasi satu jam ke depan.
Short-range forecasting	6–72 jam	Memadukan observasi dan prediksi numerik untuk evolusi cuaca jangka pendek.	Prakiraan hujan harian dan peringatan cuaca.
Medium-range forecasting	Lebih dari 72 jam hingga sekitar 15 hari	Menekankan dinamika atmosfer skala besar dan prediksi ensemble.	Prakiraan probabilistik regional atau global.

2.2.1.2 Definisi dan Ruang Lingkup Nowcasting

Dalam meteorologi operasional, nowcasting memiliki pengertian yang relatif spesifik dan dibedakan dari prakiraan cuaca pada skala waktu lain. Organisasi Meteorologi Dunia (WMO) mendefinisikan nowcasting sebagai prakiraan cuaca dengan detail lokal pada skala mesoscale dan skala yang lebih kecil, mencakup kondisi saat ini hingga sekitar 6 jam ke depan. Definisi ini menekankan tiga aspek utama: fokus pada horizon waktu sangat pendek (0–6 jam), resolusi spasial tinggi

dengan detail lokal yang relevan untuk kejadian berisiko tinggi, serta ketergantungan kuat pada informasi pengamatan terkini beresolusi tinggi [4].

Dalam penelitian ini, nowcasting difokuskan pada prediksi satu jam ke depan dengan menggunakan jendela observasi 6 jam terakhir sebagai input [5]. Pendekatan ini sesuai dengan definisi WMO sekaligus selaras dengan karakteristik dinamika cuaca di kawasan pegunungan, di mana ancaman utama seperti hujan orografis dan peningkatan kecepatan angin dapat berkembang dengan sangat cepat [9]. Horizon satu jam memberikan keseimbangan optimal antara kecepatan respons dan akurasi prediksi untuk mendukung mitigasi risiko pendakian [28].

Horizon nowcasting yang pendek ini secara konseptual berada pada rezim *initial condition-dominated*, di mana akurasi prediksi sangat bergantung pada kualitas data observasi terkini dan kemampuan model dalam menangkap pola evolusi cuaca jangka pendek [4], [5]. Berbeda dengan short-range forecasting (6–72 jam) yang lebih bergantung pada model Numerical Weather Prediction (NWP), nowcasting lebih mengandalkan data-driven learning dan ekstrapolasi dari observasi resolusi tinggi [29]. Pemahaman ini menjadi dasar pemilihan pendekatan probabilistik generatif dalam penelitian ini.

2.2.1.3 Karakteristik Dinamika pada Skala Waktu Per Jam di Wilayah Pegunungan

Skala waktu 0–6 jam erat kaitannya dengan dinamika atmosfer pada mesoscale dan convective scale [5]. Pada skala ini, proses konvektif seperti convective initiation sangat sensitif terhadap fluktuasi kecil dalam kelembapan, suhu, dan dinamika angin lokal [11]. Di wilayah orografis tropis seperti Gunung Gede–Pangrango, dinamika ini semakin kompleks karena adanya efek orografis lifting, siklus diurnal konveksi yang kuat, serta interaksi angin lereng yang menyebabkan variabilitas spasial dan temporal yang tinggi [9], [12].

Lifetime sistem konvektif umumnya berada pada orde puluhan menit hingga beberapa jam [5]. Sel konvektif tunggal dapat hidup sekitar 30–60 menit, sedangkan sistem konveksi mesoskal dapat bertahan 3–6 jam atau lebih. Oleh karena itu, prakiraan pada horizon satu jam harus mampu merepresentasikan pembentukan sel baru, pergerakan sel yang ada, serta perubahan intensitas presipitasi secara akurat

dan cepat [4], [20]. Rapid error growth akibat sifat nonlinier dan kaotik atmosfer semakin membatasi prediktabilitas deterministik pada skala ini [14].

Di kawasan Gunung Gede–Pangrango, efek topografi memperkuat dinamika mesoskal [9]. Gradien elevasi yang curam menyebabkan perbedaan kondisi meteorologis yang signifikan dalam jarak horizontal yang relatif pendek [12]. Variabilitas spasial yang tinggi ini menjadikan prakiraan per jam sebagai skala paling relevan untuk mitigasi risiko pendakian, karena ancaman cuaca dapat berkembang dan berubah secara cepat sepanjang lintasan pendakian dari hilir menuju puncak [28].

2.2.1.4 Keterbatasan Pendekatan Deterministik dan Relevansi Pendekatan Probabilistik

Model Numerical Weather Prediction (NWP) dan pendekatan deterministik berbasis machine learning sering mengalami keterbatasan signifikan pada lead time pendek untuk fenomena konvektif [14]. Siklus pembaruan model yang relatif lambat, resolusi grid yang terbatas, serta kecenderungan menghasilkan prediksi yang terlalu halus (over-smoothing) menyebabkan under-prediction pada kejadian presipitasi ekstrem [15], [29]. Model regresi yang dioptimalkan dengan fungsi kerugian berbasis mean squared error cenderung bias ke nilai rata-rata distribusi, sehingga kurang sensitif terhadap distribusi heavy-tailed presipitasi yang menjadi ciri khas hujan orografis di pegunungan [4], [27].

Selain itu, pendekatan deterministik sulit merepresentasikan ketidakpastian intrinsik atmosfer pada skala per jam [5], [14]. Ketidakpastian ini berasal dari initial condition uncertainty, model structural error, observation error, dan chaotic error growth yang tumbuh secara nonlinier [17], [30]. Akibatnya, model deterministik sering gagal memberikan informasi yang cukup bagi pengambilan keputusan berbasis risiko, terutama dalam konteks keselamatan pendaki di lingkungan pegunungan yang dinamis [28].

Pendekatan probabilistik, seperti generative diffusion models, menawarkan solusi yang lebih sesuai karena mampu memodelkan distribusi kemungkinan kondisi atmosfer masa depan daripada hanya menghasilkan satu trajektori deterministik [27]. Pendekatan ini selaras dengan sifat stokastik atmosfer pada skala per jam dan mendukung pengambilan keputusan berbasis risiko, khususnya dalam

mitigasi hipotermia pendaki [28]. Oleh karena itu, pemilihan Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning dalam penelitian ini memiliki justifikasi teoritis yang kuat [5].

Tabel 2.3 Perbandingan Keluaran Deterministik dan Probabilistik pada Nowcasting [4], [17], [27].

Aspek	Pendekatan Deterministik	Pendekatan Probabilistik
Keluaran	Satu prediksi titik untuk setiap waktu dan lokasi.	Ensemble atau distribusi beberapa prediksi yang mungkin.
Ketidakpastian	Tidak dinyatakan secara eksplisit.	Direpresentasikan melalui sebaran antar anggota ensemble.
Kegunaan	Menilai nilai prakiraan tunggal.	Mendukung keputusan berbasis peluang dan tingkat risiko.
Metrik utama	MAE, RMSE, korelasi.	CRPS, Brier Score, reliability diagram, serta metrik deterministik.
Keterbatasan	Cenderung meratakan nilai pada kondisi tidak pasti.	Memerlukan evaluasi kalibrasi dan biaya sampling lebih tinggi.

2.2.2 Dinamika Presipitasi Orografis di Pegunungan Tropis

Presipitasi orografis merupakan fenomena utama yang membentuk pola curah hujan di wilayah pegunungan, terutama di daerah tropis seperti Gunung Gede–Pangrango [9], [31]. Interaksi antara aliran angin lembab dengan topografi menghasilkan angkat paksa (orographic lifting) yang memicu pembentukan awan dan hujan intens [32]. Di kawasan tropis, proses ini sering diperkuat oleh kelembapan tinggi dan ketidakstabilan atmosfer, sehingga menghasilkan distribusi presipitasi yang sangat heterogen dalam skala spasial dan temporal yang kecil [9], [27]. Pemahaman dinamika ini menjadi krusial dalam penelitian nowcasting probabilistik karena presipitasi orografis cenderung berkembang cepat dan sulit diprediksi dengan model deterministik.

Di Gunung Gede–Pangrango, variabilitas elevasi yang tajam dari dataran rendah hingga puncak menciptakan gradien meteorologis yang signifikan [31]. Efek orografis tidak hanya meningkatkan intensitas hujan di lereng angin (windward

slope), tetapi juga menghasilkan bayangan hujan (rain shadow) di sisi lereng lindung (leeward) [9], [32]. Fenomena ini menyebabkan perbedaan kondisi cuaca yang ekstrem dalam jarak horizontal relatif pendek, sehingga sangat relevan dengan risiko hipotermia pendaki yang melintasi berbagai elevasi dalam waktu singkat [28].

Dinamika presipitasi orografis di pegunungan tropis juga dipengaruhi oleh siklus diurnal dan interaksi dengan monsun, yang mempercepat convective initiation pada skala per jam [33]. Proses ini menghasilkan presipitasi dengan distribusi heavy-tailed, di mana kejadian ekstrem lebih sering terjadi dibandingkan distribusi normal [4], [5]. Oleh karena itu, model nowcasting yang digunakan dalam penelitian ini harus mampu menangkap ketergantungan spasial-temporal antar elevasi (hilir, lereng, dan puncak) melalui pendekatan Spatio-Temporal Graph Conditioning.

2.2.2.1 Mekanisme Orographic Lifting dan Convective Initiation

Mekanisme utama presipitasi orografis adalah angkat paksa udara lembab oleh topografi, yang menyebabkan pendinginan adiabatik dan kondensasi [32]. Di wilayah tropis, angkat orografis ini sering memicu convective initiation ketika udara mencapai tingkat kebebasan konveksi (Level of Free Convection) [9]. Kecepatan angin lintang lereng (cross-slope wind) memainkan peran penting; semakin kuat angin, semakin dalam penetrasi gangguan gravitasi orografis yang mendinginkan dan melembapkan troposfer bawah, sehingga meningkatkan curah hujan hingga 20–30% per m/s peningkatan kecepatan angin [27], [32].

Berdasarkan sintesis mekanisme orographic lifting oleh Nicolas dan Boos [32], hubungan konseptual antara intensitas presipitasi orografis dan faktor atmosfer serta topografi dapat dinyatakan sebagai berikut:

$$P_{orografis} = f(U_{cross}, q, H, S, C) \quad (2.1)$$

dengan:

- $P_{orografis}$ = intensitas presipitasi orografis;
- U_{cross} = komponen kecepatan angin yang tegak lurus terhadap lereng;
- q = kelembapan udara;
- H = karakteristik elevasi/topografi;
- S = orientasi dan kemiringan lereng;

- C = kondisi konvektif atmosfer.

Rumus ini merupakan representasi konseptual, bukan persamaan empiris untuk menghitung curah hujan di Gunung Gede-Pangrango. Sumber: disusun dari Nicolas dan Boos [32].

Di Gunung Gede–Pangrango, gradien elevasi yang curam memperkuat proses lifting ini, terutama pada lereng selatan dan barat yang sering menjadi windward terhadap aliran monsun [31]. Interaksi antara angin lembab dengan topografi menghasilkan konvergensi lokal yang memicu sel konvektif baru dalam waktu singkat. Proses ini sangat dinamis pada skala per jam, sehingga memerlukan pendekatan probabilistik untuk merepresentasikan ketidakpastian convective initiation [4], [5].

Selain mekanis, faktor termal seperti pemanasan radiasi lereng pada siang hari juga berkontribusi terhadap convective initiation di pegunungan tropis [33]. Kombinasi forcing mekanis dan termal ini menghasilkan variabilitas spasial yang tinggi, di mana hujan lebat dapat terkonsentrasi di lereng tertentu sementara area berdekatan tetap relatif kering [9]. Pemahaman mekanisme ganda ini mendukung penggunaan graph neural network untuk memodelkan ketergantungan antar titik elevasi yang berbeda dalam arsitektur model penelitian ini.

2.2.2.2 Variabilitas Spasial dan Temporal Presipitasi Orografis

Presipitasi orografis di pegunungan tropis menunjukkan variabilitas spasial yang sangat tinggi akibat perbedaan elevasi, orientasi lereng, dan interaksi angin [12], [31]. Di Gunung Gede–Pangrango, curah hujan cenderung meningkat seiring kenaikan elevasi pada lereng angin hingga mencapai maksimum di zona tengah lereng, kemudian menurun di puncak atau sisi lindung [9], [32]. Variabilitas ini menciptakan microclimate yang berbeda antar elevasi, yang berdampak langsung pada kondisi termal dan kelembapan yang dialami pendaki.

Secara temporal, presipitasi orografis di wilayah tropis sering mengikuti siklus diurnal yang kuat, dengan puncak hujan pada sore hingga malam hari akibat pemanasan siang dan pelepasan ketidakstabilan [33]. Namun, pada kondisi angin lintas lereng yang kuat, siklus diurnal dapat tergantikan oleh forcing mekanis yang lebih dominan, sehingga hujan dapat terjadi kapan saja dalam skala per jam [32].

Karakteristik ini menjadikan nowcasting satu jam ke depan sangat relevan untuk mendeteksi perubahan mendadak yang berbahaya bagi keselamatan pendakian.

Distribusi temporal presipitasi orografis juga cenderung heavy-tailed, dengan kejadian ekstrem yang jarang namun berdampak besar [4], [5]. Kejadian hujan lebat yang dipicu orografi sering bersifat quasi-stationary, di mana sistem hujan bertahan lama di lereng tertentu akibat blocking dan lifting berulang [15], [31]. Variabilitas ini menekankan pentingnya pendekatan retrieval-augmented untuk menangkap analog historis kejadian ekstrem dalam model diffusion yang dikembangkan.

2.2.2.3 Relevansi dengan Nowcasting Probabilistik dan Mitigasi Risiko

Dinamika presipitasi orografis yang kompleks dan cepat berubah membatasi kemampuan model deterministik dalam memprediksi kejadian ekstrem di pegunungan tropis [5], [14]. Model regresi cenderung under-predict presipitasi berintensitas tinggi karena smoothing efek, sementara pendekatan probabilistik mampu menghasilkan distribusi kemungkinan yang lebih realistis [27]. Hal ini sangat penting untuk nowcasting di Gunung Gede–Pangrango, di mana hujan orografis dapat mempercepat kehilangan panas tubuh pendaki.

Spatio-temporal variability yang tinggi antar elevasi memerlukan representasi graph-based untuk menangkap ketergantungan antar node [5]. Pendekatan Spatio-Temporal Graph Conditioning memungkinkan model mempelajari bagaimana presipitasi di satu elevasi memengaruhi elevasi lain melalui message passing, sehingga meningkatkan sensitivitas terhadap kejadian ekstrem [4], [5].

Dengan demikian, pemahaman mendalam tentang dinamika presipitasi orografis memberikan landasan teoritis yang kuat bagi Retrieval-Augmented Diffusion Model dalam menghasilkan prediksi probabilistik yang dapat mendukung sistem peringatan dini mitigasi risiko hipotermia pendaki di kawasan pegunungan tropis seperti Gunung Gede–Pangrango [28], [32].

2.2.3 Model Generatif Probabilistik dengan Diffusion Models

Model generatif probabilistik semakin menjadi pilihan utama dalam nowcasting presipitasi karena kemampuannya menangani ketidakpastian intrinsik atmosfer pada skala per jam [4], [27]. Berbeda dengan model deterministik yang cenderung menghasilkan prediksi rata-rata dan over-smoothing, model generatif mampu menghasilkan distribusi kemungkinan skenario cuaca masa depan yang

lebih realistis [17], [30]. Dalam konteks penelitian ini, pendekatan diffusion models dipilih karena keunggulannya dalam memodelkan distribusi heavy-tailed presipitasi orografis di pegunungan tropis seperti Gunung Gede–Pangrango [5], [27].

Diffusion models bekerja berdasarkan proses forward yang secara bertahap menambahkan noise Gaussian ke data hingga menjadi noise murni, diikuti proses reverse (denoising) yang mempelajari cara mengembalikan noise menjadi data asli secara probabilistik [17], [27]. Proses ini memungkinkan model menghasilkan sampel yang beragam, sehingga sangat sesuai untuk menghasilkan ensemble prediksi nowcasting yang mencerminkan ketidakpastian alamiah atmosfer [4], [5]. Kemampuan ini menjadi landasan penting bagi pengembangan Retrieval-Augmented Diffusion Model dalam penelitian ini.

Mengacu pada formulasi forward diffusion yang digunakan oleh Asperti et al. [27], proses penambahan noise Gaussian secara bertahap pada data dapat dinyatakan sebagai berikut:

$$q(x_t|x_{t-1}) = N(x_t; \sqrt{(1 - \beta_t)} x_{t-1}, \beta_t I) \quad (2.2)$$

Selanjutnya, sesuai objektif pelatihan diffusion model yang dijelaskan oleh Asperti et al. [27], fungsi kerugian untuk meminimalkan perbedaan antara noise aktual dan noise prediksi dapat dinyatakan sebagai berikut:

$$L_{diff} = E_{x_0, \epsilon, t} \left[\left\| \epsilon - \epsilon_{\theta(x_t, t, c)} \right\|_2^2 \right] \quad (2.3)$$

dengan:

- x_0 = data target asli;
- x_t = data pada diffusion timestep t ;
- β_t = varians noise pada timestep t ;
- I = matriks identitas;
- ϵ = noise Gaussian yang ditambahkan;
- ϵ_{θ} = noise yang diprediksi model dengan parameter theta; dan
- c = kondisi tambahan, berupa representasi historis, spasial, dan retrieval.

Penerapan diffusion models pada nowcasting presipitasi telah menunjukkan peningkatan performa signifikan dibandingkan pendekatan generatif sebelumnya seperti Generative Adversarial Networks (GAN), terutama dalam hal kualitas sampel dan stabilitas pelatihan [27], [30]. Model ini mampu menghasilkan prediksi

yang lebih tajam dan lebih sensitif terhadap kejadian ekstrem, yang sangat dibutuhkan untuk mitigasi risiko hipotermia pendaki di kawasan dengan dinamika orografis yang kompleks [5], [29].

2.2.3.1 Prinsip Kerja dan Keunggulan Diffusion Models untuk Nowcasting

Diffusion models terdiri dari dua proses utama yaitu forward diffusion process dan reverse denoising process [27]. Pada proses forward, data input seperti citra radar atau field presipitasi secara bertahap ditambahkan noise hingga menjadi distribusi Gaussian murni. Proses reverse kemudian mempelajari langkah demi langkah untuk menghilangkan noise tersebut dan merekonstruksi data asli yang kondisional terhadap observasi terkini [4], [17].

Keunggulan utama diffusion models dibandingkan model generatif lain adalah kemampuannya menghindari mode collapse dan menghasilkan sampel dengan kualitas tinggi serta variasi yang realistis [27], [30]. Dalam nowcasting presipitasi, kemampuan ini sangat penting karena presipitasi pada skala per jam bersifat sangat stokastik dan memiliki distribusi heavy-tailed [5], [29]. Model ini mampu menghasilkan multiple plausible realizations yang lebih baik merepresentasikan ketidakpastian prediksi.

Selain itu, diffusion models dapat dengan mudah dikondisikan terhadap variabel tambahan seperti kondisi atmosfer sebelumnya, angin, kelembapan, dan informasi spasial elevasi [4], [27]. Kondisional ini memungkinkan integrasi dengan Spatio-Temporal Graph Conditioning, sehingga model dapat mempelajari ketergantungan antar titik observasi di Gunung Gede–Pangrango [5], [17].

2.2.3.2 Keterbatasan Model Deterministik dan Relevansi Pendekatan Generatif

Pendekatan deterministik berbasis regresi atau Numerical Weather Prediction (NWP) sering mengalami keterbatasan pada lead time pendek karena kecenderungan menghasilkan prediksi yang terlalu halus dan kurang sensitif terhadap kejadian ekstrem [14], [15]. Model ini bias terhadap nilai rata-rata distribusi, sehingga under-predict intensitas presipitasi tinggi yang sering memicu risiko hipotermia pada pendaki [29], [30].

Machine learning weather prediction models saat ini juga masih menghadapi tantangan dalam merepresentasikan ketidakpastian dan rapid error growth pada

skala per jam [14], [17]. Pendekatan probabilistik generatif menjadi solusi karena mampu memodelkan distribusi penuh kemungkinan daripada hanya satu nilai prediksi tunggal [27], [4].

Dalam konteks pegunungan tropis, di mana presipitasi orografis bersifat sangat lokal dan cepat berubah, pendekatan generatif seperti diffusion models menawarkan fleksibilitas yang lebih tinggi untuk menangkap pola kompleks yang sulit dimodelkan secara fisika murni [5], [9]. Hal ini menjadikan diffusion models sebagai pilihan yang sesuai untuk mendukung sistem peringatan dini berbasis risiko.

2.2.3.3 Relevansi dengan Retrieval-Augmented Diffusion Model

Retrieval-Augmented Diffusion Model menggabungkan kekuatan diffusion models dengan mekanisme retrieval historis untuk meningkatkan kualitas prediksi pada kejadian ekstrem [27], [30]. Dengan mengambil analog historis serupa dari database kejadian masa lalu, model dapat memperkaya proses denoising sehingga lebih akurat dalam memprediksi presipitasi intens di kawasan orografis [4], [5].

Integrasi retrieval mechanism membantu mengatasi keterbatasan data pelatihan pada kejadian langka (rare events) yang sangat berbahaya bagi pendaki [17], [29]. Kombinasi ini memungkinkan model menghasilkan ensemble prediksi yang lebih terkalibrasi dan sensitif terhadap kondisi ekstrem di Gunung Gede–Pangrango.

Dengan demikian, Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning digunakan untuk mengevaluasi kemampuan diffusion model dalam menghasilkan prediksi probabilistik yang beragam pada lingkungan pegunungan tropis yang dinamis [27], [5], [28].

2.2.4 Retrieval-Based Historical Analogs

Retrieval-based historical analogs merupakan pendekatan penting dalam meningkatkan kualitas prediksi pada kejadian ekstrem yang jarang terjadi dalam data pelatihan [27], [30]. Pendekatan ini bekerja dengan mencari kondisi historis yang mirip (analog) dari database observasi masa lalu, kemudian menggunakan informasi tersebut untuk mengkondisikan proses generasi model [4], [17]. Dalam penelitian ini, mekanisme retrieval diintegrasikan ke dalam arsitektur Diffusion

Model untuk meningkatkan akurasi dan keandalan prediksi probabilistik presipitasi pada skala per jam di kawasan Gunung Gede–Pangrango [5], [27].

Teknik retrieval memanfaatkan kemiripan fitur antara kondisi atmosfer saat ini dengan kejadian historis menggunakan jarak Euclidean L2 pada ruang fitur yang telah direduksi. Pencarian nearest neighbor dilakukan dengan FAISS `IndexFlatL2`. Dengan mengambil beberapa analogs terbaik, model dapat memperoleh informasi tambahan mengenai evolusi presipitasi, angin, dan kelembapan yang pernah terjadi pada kondisi serupa di masa lalu [17], [4]. Pendekatan ini membantu menyediakan konteks historis, namun tidak menghilangkan keterbatasan jumlah kejadian presipitasi ekstrem dalam data.

Dalam pemeringkatan analog historis menggunakan Euclidean L2, jarak antara kondisi saat ini dan kandidat analog dapat dihitung sebagai berikut:

$$d(x_q, x_i) = \sqrt{\sum_{j=1}^m (x_{q,j} - x_{i,j})^2} \quad (2.4)$$

dengan:

x_q = vektor fitur kondisi cuaca saat ini;

x_i = vektor fitur kejadian historis ke- i ;

m = jumlah dimensi fitur; dan

$d(x_q, x_i)$ = jarak Euclidean L2.

Sebanyak k kejadian historis dengan nilai jarak terkecil dipilih sebagai analog [17].

Integrasi retrieval mechanism dengan diffusion model menghasilkan arsitektur Retrieval-Augmented Diffusion Model untuk mengevaluasi manfaat konteks historis terhadap prediksi ensemble [27], [5]. Pendekatan ini menggabungkan kemampuan generatif diffusion dengan pengetahuan historis spesifik lokasi pegunungan tropis [16], [30].

2.2.4.1 Prinsip Kerja Retrieval-Based Historical Analogs

Retrieval-based historical analogs bekerja dengan membangun database indeks dari seluruh data historis observasi atmosfer menggunakan struktur data efisien seperti FAISS (Facebook AI Similarity Search) [27], [30]. Pada saat inferensi, kondisi atmosfer saat ini (current state) di-query ke database untuk

mencari k nearest neighbors berdasarkan kesamaan fitur multivariat, termasuk presipitasi lag, kelembapan, suhu, dan kecepatan angin [17], [4].

Setelah analogs historis berhasil diambil, informasi dari analogs tersebut kemudian digunakan sebagai conditioning tambahan pada proses denoising diffusion model [5], [27]. Kondisional ini membantu model membimbing proses reverse diffusion menuju trajektori yang lebih realistis, terutama ketika menghadapi kejadian di luar distribusi umum data pelatihan [29], [30].

Keunggulan utama pendekatan ini adalah kemampuannya meningkatkan performa prediksi pada rare events tanpa harus meningkatkan ukuran model secara signifikan [16], [17]. Dalam konteks nowcasting satu jam ke depan, retrieval analogs memberikan konteks historis yang berharga untuk memprediksi evolusi presipitasi orografis di sekitar Gunung Gede–Pangrango.

2.2.4.2 Keunggulan Retrieval-Augmented dibandingkan Pure Generative Models

Pure generative models seperti diffusion models standar sering mengalami kesulitan dalam memprediksi kejadian ekstrem karena keterbatasan jumlah sampel langka dalam dataset pelatihan [14], [27]. Akibatnya, model cenderung menghasilkan prediksi yang kurang tajam atau bias terhadap pola rata-rata [15], [29].

Retrieval-Augmented approach mengatasi masalah tersebut dengan menyuntikkan pengetahuan historis langsung ke dalam proses generasi [27], [30]. Dengan menyediakan analogs yang relevan, model dapat mempelajari pola transisi dari kondisi serupa di masa lalu, sehingga meningkatkan kemampuan generalisasi pada kasus ekstrem yang berbahaya bagi pendaki [5], [17].

Selain itu, pendekatan retrieval juga meningkatkan interpretabilitas model karena dapat menunjukkan analogs historis mana yang paling berpengaruh terhadap prediksi saat ini [16], [4]. Hal ini memberikan nilai tambah bagi pengembangan sistem decision support untuk mitigasi risiko hipotermia di kawasan pegunungan.

2.2.5 Spatio-Temporal Graph Conditioning pada Representasi Data Elevasi

Representasi data spatio-temporal menjadi sangat penting dalam nowcasting presipitasi di wilayah pegunungan karena adanya ketergantungan kuat antar lokasi yang berbeda posisi relatif terhadap titik observasi utama [9], [12]. Dalam penelitian

ini, lima titik observasi direpresentasikan sebagai node dalam graph, yaitu MAIN, UP, DOWN, LEFT, dan RIGHT, dengan node MAIN sebagai target prediksi utama [5], [31]. Pendekatan Spatio-Temporal Graph Conditioning memungkinkan model mempelajari hubungan spasial dan temporal antar kelima node ini secara simultan, sehingga lebih mampu menangkap dinamika lokal presipitasi orografis di sekitar lokasi pendakian Gunung Gede–Pangrango [17], [30].

Graph Neural Network (GNN), khususnya Graph Attention Network (GAT), merepresentasikan kelima titik observasi sebagai node dalam graph, dengan node MAIN sebagai pusat perhatian utama [14], [5]. Node UP, DOWN, LEFT, dan RIGHT merepresentasikan posisi relatif di sekitar node utama, sehingga memungkinkan model menangkap pengaruh angin, propagasi awan, dan presipitasi dari berbagai arah terhadap kondisi di titik MAIN [9], [12]. Struktur graph ini lebih fleksibel dan komprehensif dibandingkan representasi linier sederhana untuk memodelkan lingkungan mikro di pegunungan tropis.

Integrasi Spatio-Temporal Graph Conditioning ke dalam arsitektur Retrieval-Augmented Diffusion Model meningkatkan kemampuan model dalam menangani variabilitas spasial tinggi yang menjadi ciri khas presipitasi orografis [31], [9]. Pendekatan ini sangat relevan untuk mitigasi risiko hipotermia karena memungkinkan prediksi yang lebih akurat pada titik MAIN, yang dapat mewakili posisi pendaki atau lokasi krusial di sepanjang jalur pendakian [28], [15].

2.2.5.1 Representasi Graph untuk Data Elevasi dengan Lima Node

Dalam model ini, lima titik observasi direpresentasikan sebagai node dalam graph spatio-temporal, yaitu node MAIN sebagai target utama, serta node UP, DOWN, LEFT, dan RIGHT yang merepresentasikan posisi relatif di sekitarnya [12], [31]. Setiap node dilengkapi dengan fitur meteorologis seperti presipitasi lag, suhu udara, kelembapan relatif, kecepatan angin, dan variabel atmosfer lainnya pada beberapa waktu observasi sebelumnya [5], [17]. Node MAIN menjadi pusat perhatian karena menjadi lokasi utama yang diprediksi.

Graph Attention Network (GAT) digunakan untuk memproses graph ini karena kemampuannya memberikan bobot perhatian yang adaptif terhadap node tetangga [14], [30]. Melalui mekanisme attention, model dapat mempelajari seberapa besar pengaruh node UP, DOWN, LEFT, dan RIGHT terhadap evolusi

kondisi cuaca di node MAIN pada horizon satu jam ke depan [5], [17]. Struktur graph menggunakan topologi star: node MAIN terhubung dua arah dengan UP, DOWN, LEFT, dan RIGHT, sedangkan node tetangga tidak saling terhubung.

Tabel 2.4 Definisi Node pada Representasi Graph Lima Node [9], [12], [31]

Node	Posisi Relatif terhadap MAIN	Fungsi dalam Model	Koneksi Graph
MAIN	Titik prediksi utama.	Menyediakan target curah hujan, kecepatan angin, dan kelembapan relatif pada $t+1$.	Terhubung dua arah dengan UP, DOWN, LEFT, RIGHT.
UP	Utara dari MAIN.	Menyediakan konteks kondisi atmosfer dari arah utara.	Terhubung dua arah dengan MAIN
DOWN	Selatan dari MAIN.	Menyediakan konteks kondisi atmosfer dari arah selatan.	Terhubung dua arah dengan MAIN
LEFT	Barat dari MAIN.	Menyediakan konteks kondisi atmosfer dari arah barat.	Terhubung dua arah dengan MAIN
RIGHT	Timur dari MAIN.	Menyediakan konteks kondisi atmosfer dari arah timur.	Terhubung dua arah dengan MAIN

2.2.5.2 Keunggulan Spatio-Temporal Graph dibandingkan Pendekatan Konvensional

Pendekatan sequence-based atau grid-based konvensional sering kali kurang efektif dalam menangkap ketergantungan spasial non-Euclidean yang kompleks di wilayah pegunungan [14], [15]. Model berbasis CNN atau LSTM umumnya mengasumsikan hubungan spasial tetap atau hanya lokal, sehingga sulit memodelkan interaksi multidirectional dari berbagai arah terhadap satu titik utama [29], [30].

Spatio-Temporal Graph Conditioning mampu mengatasi keterbatasan tersebut dengan secara eksplisit memodelkan hubungan antar node melalui message passing dan attention mechanism [5], [17]. Pendekatan ini memungkinkan model mempelajari pola propagasi presipitasi orografis dan pengaruh angin dari berbagai arah secara lebih akurat pada skala per jam [9], [31].

Integrasi graph conditioning dengan diffusion model memungkinkan proses denoising dilakukan secara kondisional terhadap struktur graph lima node, sehingga menghasilkan prediksi ensemble yang lebih konsisten secara spasial dan lebih sensitif terhadap kondisi lokal di sekitar node MAIN [27], [5]. Keunggulan ini sangat penting untuk meningkatkan akurasi prediksi pada titik krusial yang digunakan untuk mitigasi risiko.

2.2.6 Risiko Hipotermia dan Mitigasi Pendakian

Risiko hipotermia merupakan ancaman serius bagi keselamatan pendaki di pegunungan, termasuk di kawasan tropis seperti Gunung Gede–Pangrango [28]. Hipotermia terjadi ketika suhu inti tubuh manusia turun di bawah 35°C akibat kehilangan panas yang melebihi produksi panas tubuh [28], [34]. Di pegunungan tropis, hipotermia sering disebabkan oleh kombinasi hujan deras, angin kencang, dan kelembapan tinggi yang mempercepat kehilangan panas melalui konduksi, konveksi, dan evaporasi, meskipun suhu udara tidak ekstrem seperti di pegunungan tinggi bersalju [28], [22].

Kondisi cuaca di Gunung Gede–Pangrango yang dinamis, terutama presipitasi orografis disertai angin, dapat menyebabkan hipotermia “wet-cold” (hipotermia basah-dingin) dengan cepat [28]. Pakaian yang basah kehilangan kemampuan isolasi hingga 90%, sementara angin memperbesar efek wind chill, sehingga mempercepat penurunan suhu tubuh pendaki meskipun berada di elevasi sedang hingga tinggi [28], [34]. Kejadian ini semakin berbahaya karena pendaki sering berada dalam kondisi kelelahan setelah berjalan jauh, sehingga kemampuan tubuh untuk menghasilkan panas menurun secara signifikan [22].

Nowcasting probabilistik presipitasi, kecepatan angin, dan kelembapan relatif menjadi sangat relevan sebagai sistem peringatan dini. Prediksi satu jam ke depan dengan pendekatan probabilistik memungkinkan pendeteksian dini kombinasi faktor berisiko tinggi sebelum kondisi hipotermia berkembang [4], [5]. Penelitian ini menghubungkan output model Retrieval-Augmented Diffusion dengan Spatio-Temporal Graph Conditioning secara langsung dengan mitigasi risiko keselamatan pendaki.

2.2.6.1 Mekanisme Hipotermia di Lingkungan Pegunungan Tropis

Hipotermia di pegunungan tropis berbeda dengan kasus klasik di daerah dingin karena suhu udara relatif hangat, namun kelembapan tinggi dan hujan deras menjadi faktor dominan [28]. Mekanisme utama meliputi konduksi panas langsung ke pakaian dan kulit yang basah, konveksi yang dipercepat oleh angin, serta evaporasi yang terus berlangsung pada pakaian lembab [28], [34]. Kombinasi ketiga mekanisme ini menyebabkan kehilangan panas yang cepat bahkan pada suhu udara di atas 10–15°C.

Di Gunung Gede–Pangrango, efek orografis sering menghasilkan hujan lebat secara tiba-tiba disertai peningkatan kecepatan angin seiring kenaikan elevasi [9], [31]. Kondisi ini sangat berbahaya bagi pendaki karena perubahan cuaca dapat terjadi dalam waktu singkat sepanjang jalur pendakian, dari zona hilir hingga menuju puncak [28]. Selain itu, kelelahan fisik dan penurunan kadar gula darah akibat aktivitas berkepanjangan semakin memperbesar kerentanan terhadap hipotermia [22], [34].

Gejala awal hipotermia seperti menggigil, kelelahan, dan penurunan koordinasi motorik sering diabaikan pendaki karena dianggap sebagai kelelahan biasa, padahal kondisi ini dapat berkembang cepat menjadi hipotermia sedang hingga berat yang mengancam nyawa [28]. Oleh karena itu, pemantauan dini melalui prediksi cuaca probabilistik menjadi krusial.

2.2.6.2 Faktor Meteorologis Pemicu Risiko Hipotermia

Faktor meteorologis utama yang memicu hipotermia di pegunungan tropis adalah kombinasi curah hujan tinggi, kecepatan angin, dan kelembapan relatif yang tinggi [28], [5]. Hujan orografis yang intens membasahi pakaian secara cepat, sementara angin memperbesar efek convective heat loss [9], [31]. Kelembapan udara yang tinggi menghambat penguapan keringat dan memperburuk sensasi dingin pada tubuh.

Tabel 2.5 Faktor Meteorologis terkait Paparan Dingin Pendaki [28], [22]

Faktor	Dampak Potensial	Variabel Model	Peran Informasi Nowcasting
Presipitasi	Membasahi pakaian dan meningkatkan kehilangan panas melalui konduksi serta evaporasi.	Curah hujan.	Memberi peringatan peluang hujan pada satu jam berikutnya.
Kecepatan angin	Meningkatkan kehilangan panas melalui konveksi dan efek wind chill.	Kecepatan angin.	Mengidentifikasi kondisi angin yang berpotensi memperburuk paparan.
Kelembapan relatif	Memengaruhi penguapan dan kondisi pakaian basah.	Kelembapan relatif.	Melengkapi interpretasi kondisi basah dan kenyamanan termal.

Pada node utama (MAIN) yang menjadi fokus prediksi model ini, variabilitas dari node UP, DOWN, LEFT, dan RIGHT dapat memengaruhi kondisi lokal secara signifikan [5], [17]. Misalnya, angin dari arah tertentu dapat membawa hujan lebih deras ke titik MAIN, sehingga meningkatkan risiko hipotermia dalam waktu singkat [28]. Pendekatan lima node pada Spatio-Temporal Graph Conditioning memungkinkan model menangkap dinamika multidirectional ini dengan lebih baik.

Kombinasi variabel tersebut sulit diprediksi secara akurat dengan model deterministik karena sifat stokastik dan heavy-tailed dari presipitasi orografis [4], [27]. Oleh karena itu, pendekatan probabilistik yang menghasilkan distribusi kemungkinan menjadi lebih sesuai untuk mendukung pengambilan keputusan keselamatan pendaki.

2.2.6.3 Relevansi Nowcasting Probabilistik sebagai Mitigasi Risiko

Nowcasting probabilistik presipitasi dengan horizon satu jam ke depan dapat menyediakan informasi bagi tindakan preventif, seperti mencari tempat berteduh, mengganti pakaian basah, atau memutuskan untuk turun sebelum kondisi memburuk [28], [26]. Output model berupa distribusi probabilitas pada node MAIN dapat menjadi masukan bagi pengembangan indeks risiko hipotermia multi-faktor pada penelitian lanjutan; indeks tersebut bukan keluaran yang diimplementasikan dalam penelitian ini.

Integrasi Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning memungkinkan prediksi yang lebih sensitif terhadap kejadian ekstrem yang berpotensi memicu hipotermia [27], [5]. Pendekatan ini tidak hanya meningkatkan akurasi teknis, tetapi juga memberikan nilai praktis langsung sebagai decision support system untuk pengelola taman nasional dan komunitas pendaki Gunung Gede–Pangrango.

Dengan demikian, penelitian ini menghubungkan kemajuan teknologi nowcasting probabilistik dengan kebutuhan keselamatan manusia di lingkungan pegunungan tropis. Model yang dikembangkan diharapkan dapat berkontribusi pada pengurangan kejadian hipotermia dan peningkatan keselamatan aktivitas pendakian melalui sistem peringatan dini berbasis data yang akurat dan tepat waktu [28], [3], [26].

2.3 Analisis Celah Penelitian

Penelitian terkini dalam nowcasting presipitasi telah menunjukkan kemajuan melalui penerapan model generatif probabilistik, khususnya diffusion models [4], [27]. Model-model tersebut menyediakan prediksi ensemble, tetapi performanya tetap bergantung pada data, metrik, dan karakteristik kejadian ekstrem [5], [17]. Sebagian besar studi masih berfokus pada data radar resolusi tinggi di wilayah dataran atau lautan, dengan sedikit perhatian pada karakteristik presipitasi orografis di pegunungan tropis yang memiliki variabilitas spasial dan temporal yang sangat tinggi [9], [31].

Meskipun beberapa penelitian telah mengintegrasikan aspek fisika orografis ke dalam model nowcasting, pendekatan yang digunakan umumnya masih berbasis grid-based atau sequence modeling yang kurang efektif dalam menangkap ketergantungan multidirectional antar lokasi pada gradien elevasi yang curam [12], [14]. Selain itu, model diffusion yang ada sering kali mengalami kesulitan dalam memprediksi kejadian ekstrem karena keterbatasan data langka (rare events), sehingga cenderung under-predict intensitas presipitasi tinggi yang menjadi pemicu utama risiko hipotermia [27], [29]. Celah ini semakin terlihat pada konteks pegunungan tropis seperti Gunung Gede–Pangrango, di mana interaksi angin lintas lereng dan siklus diurnal memainkan peran penting.

Penelitian sebelumnya juga jarang menggabungkan mekanisme retrieval historical analogs dengan diffusion models secara spesifik untuk nowcasting satu jam ke depan di lingkungan orografis [30], [16]. Kebanyakan studi hanya menggunakan pure generative approach atau retrieval sederhana tanpa integrasi yang mendalam dengan representasi graph untuk menangani variabilitas spasial dari berbagai arah. Selain itu, aplikasi model nowcasting probabilistik untuk mitigasi risiko keselamatan manusia, khususnya hipotermia pada aktivitas pendakian di pegunungan tropis, masih sangat terbatas [28], [26]. Mayoritas penelitian lebih berorientasi pada aspek teknis akurasi model daripada penerapan langsung sebagai sistem peringatan dini berbasis risiko.

2.3.1.1 Celah pada Representasi Spasial dan Temporal

Pendekatan konvensional seperti CNN, LSTM, atau transformer murni belum optimal dalam memodelkan ketergantungan spasial non-Euclidean yang kompleks di wilayah pegunungan [14], [15]. Representasi lima node (MAIN, UP, DOWN, LEFT, RIGHT) dengan node MAIN sebagai target utama belum banyak dieksplorasi dalam literatur nowcasting presipitasi orografis [5], [9]. Celah ini menyebabkan model sulit menangkap pengaruh multidirectional dari berbagai arah terhadap titik prediksi utama.

2.3.1.2 Celah pada Penanganan Kejadian Ekstrem dan Ketidakpastian

Banyak model diffusion saat ini masih kurang optimal dalam menangani distribusi heavy-tailed presipitasi ekstrem di lingkungan tropis tanpa bantuan informasi historis yang relevan [27], [29]. Penggunaan retrieval-based historical analogs yang dikombinasikan dengan proses denoising diffusion masih jarang diterapkan, terutama pada horizon nowcasting satu jam dengan data reanalysis atau stasiun permukaan [30], [17].

2.3.1.3 Celah pada Aplikasi Mitigasi Risiko Pendakian

Terdapat kesenjangan antara kemajuan teknologi nowcasting probabilistik dengan aplikasi mitigasi keselamatan pendakian di pegunungan tropis [28], [3]. Pengembangan indeks risiko hipotermia berbasis multi-faktor dari keluaran probabilistik merupakan peluang penelitian lanjutan, bukan komponen yang diimplementasikan dalam penelitian ini [26], [22].

Berdasarkan analisis celah tersebut, penelitian ini mengusulkan Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning menggunakan representasi lima node dengan MAIN sebagai target utama. Penelitian mengevaluasi retrieval historical analogs, diffusion probabilistik, dan representasi graph untuk dinamika orografis Gunung Gede–Pangrango; manfaatnya terhadap mitigasi keselamatan ditafsirkan dari hasil evaluasi, bukan diasumsikan sebelumnya.

BAB III

METODE PENELITIAN

3.1 Pendekatan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif dengan metode eksperimental berbasis pengembangan model (*model development research*). Pendekatan ini dipilih karena penelitian bertujuan untuk merancang, mengimplementasikan, dan mengevaluasi performa sebuah model machine learning baru, yaitu Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning, untuk melakukan nowcasting probabilistik presipitasi satu jam ke depan.

Penelitian bersifat eksperimental karena melibatkan manipulasi variabel arsitektur model (seperti penggunaan retrieval mechanism, graph conditioning dengan lima node, dan weighted denoising loss), serta pengujian terhadap berbagai skenario eksperimen untuk membandingkan performa model yang diusulkan dengan baseline. Pendekatan ini selaras dengan karakteristik penelitian rekayasa komputasional yang menekankan pada pembangunan sistem, pengujian, dan validasi terhadap data real-world.

Metode pengembangan model dilakukan secara terstruktur melalui tahapan pengambilan data, preprocessing, pembentukan graph, pelatihan, inferensi, hingga evaluasi. Penekanan utama diberikan pada aspek probabilistik dan sensitivitas terhadap kejadian ekstrem, mengingat aplikasi utama penelitian ini adalah mitigasi risiko hipotermia pendaki di kawasan Gunung Gede–Pangrango. Dengan demikian, penelitian ini tidak hanya bersifat teknis, tetapi juga berorientasi pada solusi praktis berbasis kecerdasan buatan.

3.2 Studi Literatur

Studi literatur dalam penelitian ini dilakukan untuk mengidentifikasi, menganalisis, dan mensintesis berbagai kajian terdahulu yang relevan dengan pengembangan model nowcasting probabilistik presipitasi berbasis deep learning. Fokus utama kajian mencakup tiga aspek penting, yaitu: (1) teknik nowcasting presipitasi pada skala jam-an, (2) penerapan model generatif probabilistik khususnya diffusion models, serta (3) pendekatan spatio-temporal graph dan retrieval-augmented mechanism dalam pemodelan cuaca.

Berbagai penelitian menempatkan diffusion models sebagai pendekatan untuk menghasilkan distribusi probabilistik pada nowcasting presipitasi [4], [27]. Sensitivitas terhadap kejadian ekstrem tetap harus diuji secara empiris, terutama pada distribusi heavy-tailed presipitasi orografis [5], [17]. Namun, sebagian besar studi masih menggunakan data radar resolusi tinggi dan jarang mengeksplorasi data reanalysis ERA5 pada wilayah pegunungan tropis dengan variabilitas elevasi yang tinggi.

Beberapa penelitian juga telah mengintegrasikan Graph Neural Network (GNN) untuk menangkap ketergantungan spasial dalam data meteorologi [30]. Pendekatan ini terbukti efektif dalam memodelkan interaksi antar lokasi, namun masih terbatas pada representasi grid-based atau sequence modeling yang kurang optimal untuk konfigurasi node multidirectional seperti lima node (MAIN, UP, DOWN, LEFT, RIGHT) yang digunakan dalam penelitian ini. Selain itu, penerapan retrieval-based historical analogs pada diffusion models untuk meningkatkan performa pada rare events masih belum banyak dieksplorasi, khususnya dalam konteks nowcasting satu jam ke depan [27], [16].


Dari sisi aplikasi, literatur menunjukkan bahwa integrasi nowcasting probabilistik dengan mitigasi risiko bencana, khususnya hipotermia pada aktivitas pendakian di pegunungan tropis, masih sangat terbatas [28], [3]. Kebanyakan penelitian lebih berfokus pada aspek teknis akurasi model daripada penerapan praktis sebagai early warning system berbasis risiko.

Studi literatur ini menjadi dasar dalam merancang metodologi penelitian, khususnya pada pemilihan arsitektur Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning menggunakan lima node observasi. Dengan mensintesis berbagai celah dan keunggulan dari studi sebelumnya, penelitian ini diharapkan dapat berkontribusi baik secara metodologis maupun aplikatif dalam pengembangan model nowcasting yang lebih akurat dan bermanfaat untuk mitigasi risiko keselamatan pendaki di Gunung Gede–Pangrango.

3.3 Tahapan Penelitian

Tahapan penelitian dalam penelitian ini dirancang secara sistematis dan berurutan untuk mendukung pengembangan model Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph Conditioning. Seluruh proses mengikuti alur

metodologi yang terstruktur mulai dari pengambilan data hingga evaluasi dan pemetaan skenario eksperimen. Gambar 3.1 berikut mengilustrasikan alur penelitian secara keseluruhan yang terdiri dari sembilan tahapan utama.



Gambar 3.1 Diagram Alur Tahapan Penelitian

Proses penelitian diawali dengan Pengambilan Data, yaitu pengumpulan data meteorologi per jam dari Open-Meteo Archive API berbasis ERA5 reanalysis pada lima titik observasi spasial (MAIN, UP, DOWN, LEFT, RIGHT). Tahap ini menjadi fondasi utama karena kualitas dan kelengkapan data sangat menentukan keberhasilan tahapan berikutnya.

Selanjutnya dilakukan Preprocessing Data yang meliputi validasi struktur, pembersihan, pembentukan fitur lag, transformasi logaritmik pada presipitasi, serta normalisasi data menggunakan Standard Scaling untuk memastikan data siap digunakan dalam pelatihan model.

Kemudian dilakukan Pembagian Dataset secara temporal (time-based split) untuk memisahkan data menjadi training, validation, dan testing set. Pembagian ini

penting untuk menjaga aspek temporal order dan mencegah data leakage pada evaluasi model.

Tahap Pembentukan Fitur dan Graf melibatkan rekayasa fitur serta pembuatan struktur graph spatio-temporal dengan lima node di mana node MAIN menjadi target prediksi utama. Graf ini merepresentasikan ketergantungan spasial multidirectional antar node.

Selanjutnya adalah Perancangan Arsitektur Model yang mendefinisikan keseluruhan komponen Retrieval-Augmented Diffusion Model, termasuk mekanisme retrieval historical analogs dan Spatio-Temporal Graph Conditioning menggunakan Graph Attention Network (GAT).

Proses Proses Pelatihan Model dilakukan dengan menggunakan weighted denoising loss untuk meningkatkan sensitivitas model terhadap kejadian presipitasi ekstrem serta teknik conditional diffusion berdasarkan observasi historis dan struktur graph.

Setelah model dilatih, dilakukan Prosedur Inferensi yang menghasilkan prediksi probabilistik satu jam ke depan berupa distribusi sampel ensemble pada node MAIN.

Tahap Evaluasi Model kemudian dilakukan menggunakan metrik deterministik (MAE, RMSE), metrik probabilistik (CRPS), serta metrik berbasis threshold (POD, FAR, CSI) untuk menilai performa model secara komprehensif.


Tahap terakhir, Pemetaan Skenario Eksperimen Model dilakukan untuk menguji berbagai variasi konfigurasi model, hyperparameter, dan baseline perbandingan guna menganalisis kontribusi masing-masing komponen terhadap peningkatan performa.

Dengan alur tahapan yang terstruktur seperti yang ditunjukkan pada Gambar 3.1, penelitian ini memastikan bahwa setiap komponen model dikembangkan secara bertahap dan dapat dievaluasi secara ilmiah.

3.3.1 Pengambilan Data

Pengambilan data merupakan tahap awal yang sangat krusial dalam penelitian ini karena menjadi fondasi bagi seluruh proses pengembangan model. Penelitian ini menggunakan data sekunder berupa deret waktu multivariat dengan referensi spasial tetap yang diperoleh melalui layanan Open-Meteo Archive API berbasis

reanalisis ERA5. Pemilihan ERA5 didasarkan pada konsistensi historis jangka panjang, kelengkapan variabel meteorologis, serta resolusi spasial dan temporal yang seragam [31], [34]. ERA5 adalah reanalysis historis, bukan sumber observasi real-time; karena itu penggunaannya dibatasi untuk pelatihan dan evaluasi metodologis, bukan operasi nowcasting langsung. Proses pengambilan data melalui Open-Meteo Archive API dapat dilihat pada Gambar 3.2 berikut.



Gambar 3.2 Diagram Proses Pengambilan Data ERA5 melalui Open-Meteo API

Gambar 3.2 mengilustrasikan alur pengambilan data yang dimulai dari penentuan Koordinat Node, permintaan data melalui Open-Meteo API, perolehan ERA5 Dataset, dilanjutkan dengan Validasi Data Grid, Penggabungan Data Semua Node, hingga menghasilkan Dataset Penelitian yang siap digunakan. Diagram ini menekankan mekanisme validasi grid center untuk mencegah duplikasi spasial serta konsistensi penggabungan data dari kelima node.

Data dikumpulkan dengan resolusi temporal per jam (*hourly*) mencakup periode 1 Januari 2005 hingga 31 Desember 2025. Pengambilan data dilakukan pada lima titik grid tetap yang mewakili wilayah studi Gunung Gede–Pangrango. Satu titik ditetapkan sebagai node utama (MAIN) yang berfungsi sebagai target prediksi, sedangkan empat titik lainnya berperan sebagai node konteks spasial (UP, DOWN, LEFT, dan RIGHT) untuk memperkaya informasi multidirectional di sekitar node utama.

Posisi spasial kelima node observasi yang digunakan dalam penelitian ini ditampilkan pada Gambar 3.3.



Gambar 3.3 Posisi Lima Node Pengamatan pada Wilayah Studi Gunung Gede–Pangrango

Gambar 3.3 memperlihatkan distribusi spasial kelima node di sekitar kawasan Gunung Gede–Pangrango. Node MAIN diposisikan sebagai titik representatif utama, sementara node UP, DOWN, LEFT, dan RIGHT dirancang untuk menangkap variasi kondisi atmosfer dari berbagai arah dan elevasi di sekitar node utama. Koordinat masing-masing node ditentukan secara strategis dan ditunjukkan pada Tabel 3.1.

Tabel 3.1 Koordinat Node

Node	Latitude	Longitude
MAIN	-6.75	107.00
UP	-6.50	107.00
DOWN	-7.00	107.00
LEFT	-6.75	106.75
RIGHT	-6.75	107.25

Untuk menjamin akurasi representasi spasial, dilakukan validasi terhadap grid center yang dikembalikan oleh API. Proses validasi ini bertujuan mencegah *grid collision*, yaitu kondisi ketika dua koordinat berbeda jatuh pada grid ERA5 yang

sama. Apabila ditemukan duplikasi, proses pengambilan data dihentikan secara otomatis dan koordinat ditinjau ulang.

Data dari kelima node kemudian digabungkan menjadi satu dataset terpadu dengan urutan node yang konsisten, yaitu [MAIN, UP, DOWN, LEFT, RIGHT] pada setiap timestamp. Konsistensi urutan ini sangat penting untuk menjaga kesesuaian representasi graph spatio-temporal pada tahap selanjutnya.

Karakteristik keseluruhan dataset yang berhasil diperoleh ditunjukkan pada Tabel 3.2.

Tabel 3.2 Karakteristik Dataset Penelitian

Karakteristik	Nilai
Sumber Data	Open-Meteo (ERA5)
Resolusi Temporal	1 Jam
Periode Data	2005–2025
Jumlah Node	5
Jumlah Timestamp	184.080
Total Observasi	920.400
Jumlah Variabel	21

Dengan prosedur pengambilan data yang terstruktur, tervalidasi, dan didukung visualisasi spasial, dataset yang dihasilkan memiliki integritas spasial dan temporal yang tinggi, sehingga siap digunakan pada tahapan preprocessing dan pemodelan selanjutnya.

3.3.2 Preprocessing Data

Tahap preprocessing data merupakan proses krusial yang bertujuan untuk meningkatkan kualitas, konsistensi, dan kesesuaian data sebelum digunakan dalam pelatihan model Retrieval-Augmented Diffusion dengan Spatio-Temporal Graph Conditioning. Proses ini meliputi validasi struktur, harmonisasi, pembentukan fitur temporal, transformasi distribusi, dan normalisasi. Dengan preprocessing yang teliti, potensi kesalahan akibat ketidaksesuaian data dapat diminimalisir, sehingga stabilitas dan performa model dapat ditingkatkan [31], [34].



Gambar 3.4 Diagram Alur Preprocessing Data

Gambar 3.4 mengilustrasikan alur preprocessing data secara keseluruhan, mulai dari dataset mentah hingga dataset siap pemodelan. Diagram ini menunjukkan urutan tahapan yang saling terkait untuk memastikan integritas data sepanjang pipeline.

Tahap pertama adalah validasi struktur data. Pemeriksaan dilakukan terhadap kelengkapan lima node pada setiap timestamp, urutan node yang harus konsisten ([MAIN, UP, DOWN, LEFT, RIGHT]), kesesuaian nama kolom, serta keberadaan nilai tidak valid. Validasi ini bersifat *fail-fast*, yaitu proses dihentikan apabila ditemukan ketidaksesuaian untuk mencegah propagasi kesalahan ke tahap berikutnya.

Selanjutnya dilakukan pembentukan fitur temporal. Untuk menangkap ketergantungan waktu pada horizon nowcasting satu jam, dibuat fitur *lag* curah hujan satu jam sebelumnya (*precipitation_lag1*). Fitur ini dihitung menggunakan persamaan berikut:

$$PrecipitationLag1_t = Precipitation_{t-1} \quad (3.1)$$

Dengan:

- $PrecipitationLag1_t$ = nilai curah hujan satu jam sebelumnya pada waktu t
- $Precipitation_{t-1}$ = nilai curah hujan pada waktu sebelumnya ($t - 1$)

Pada timestamp pertama setiap node, nilai lag diinisialisasi dengan nol. Penambahan fitur lag ini penting karena curah hujan memiliki autokorelasi temporal yang kuat pada skala jam-an [5], [4].

Tahap berikutnya adalah transformasi variabel curah hujan. Variabel ini memiliki distribusi yang sangat skewed dan didominasi oleh nilai nol dengan sedikit kejadian ekstrem. Untuk mengurangi skewness dan meningkatkan stabilitas pelatihan, dilakukan transformasi logaritmik menggunakan fungsi:

$$y' = \log(1 + y) \quad (3.2)$$

dengan:

- y = nilai curah hujan asli
- y' = nilai curah hujan setelah transformasi

Transformasi ini membantu model lebih baik dalam mempelajari pola presipitasi orografis yang bersifat heavy-tailed. Sebagai contoh untuk nilai curah hujan sebesar 2.40 mm maka $y = 2.40 \text{ mm}$, diperoleh nilai curah hujan setelah transformasi sebagai berikut $y' = \log(1 + 2.40) = 1.2238$

Setelah transformasi, seluruh fitur dan variabel target dinormalisasi menggunakan Standard Scaling. Proses normalisasi dilakukan dengan persamaan:

$$z = \frac{y' - \mu}{\sigma + \epsilon} \quad (3.3)$$

dengan:

- z = nilai hasil normalisasi
- y' = nilai curah hujan setelah transformasi
- μ = rata-rata (mean) dari data pelatihan
- σ = simpangan baku (standard deviation) dari data pelatihan
- ϵ = konstanta kecil untuk menghindari pembagian dengan nol

Parameter μ dan σ dihitung hanya dari data pelatihan untuk mencegah *data leakage*. Parameter yang sama kemudian diterapkan pada data validasi dan data uji. Dengan $y' = 1.2238, \mu = 0.60, \sigma = 0.90, \epsilon = 0.000001$, diperoleh nilai hasil normalisasi sebagai berikut $z = \frac{1.2238 - 0.60}{0.90 + 0.000001} = 0.6931$.


Melalui serangkaian tahapan preprocessing yang terstruktur ini, data yang dihasilkan tidak hanya memiliki kualitas tinggi, tetapi juga telah disesuaikan secara statistik agar sesuai dengan karakteristik arsitektur model probabilistik yang sensitif

terhadap distribusi dan ketergantungan spasial-temporal. Proses ini memastikan bahwa input yang diberikan kepada model mencerminkan dinamika atmosfer nyata di kawasan Gunung Gede–Pangrango secara optimal.

3.3.3 Pembagian Dataset Temporal

Setelah melalui tahap preprocessing, dataset selanjutnya dibagi menjadi tiga himpunan yaitu data pelatihan (*training set*), data validasi (*validation set*), dan data pengujian (*test set*). Pembagian ini bertujuan untuk mendukung proses pelatihan model, pemilihan hyperparameter, serta evaluasi performa yang objektif dan tidak bias terhadap data yang belum pernah dilihat oleh model. Karena data meteorologis bersifat deret waktu dengan ketergantungan temporal yang kuat, penelitian ini menggunakan pembagian temporal (*time-based split*) daripada pembagian acak [4], [17].

Pendekatan temporal split dipilih untuk menjaga urutan kronologis data, sehingga model hanya mempelajari pola dari periode masa lalu dan dievaluasi pada periode masa depan. Skema pembagian dataset yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.5.



Gambar 3.5 Ilustrasi Pembagian Dataset Temporal

Gambar 3.5 menampilkan diagram garis waktu yang menggambarkan pembagian dataset secara kronologis menjadi tiga periode utama. Visualisasi ini memperjelas bahwa model dilatih hanya menggunakan data historis dan diuji pada data masa depan yang sepenuhnya tidak terlibat dalam proses pelatihan.

Salah satu tujuan utama pembagian temporal adalah mencegah *data leakage*. *Data leakage* terjadi ketika informasi dari masa depan secara tidak sengaja digunakan selama pelatihan, sehingga menghasilkan estimasi performa yang terlalu optimistis [14], [17]. Dalam penelitian ini, beberapa langkah pencegahan diterapkan, antara lain:

- Pembagian dilakukan secara kronologis tanpa pengacakan (*shuffle*).
- Statistik normalisasi dihitung hanya dari data pelatihan.

- Basis data retrieval hanya dibangun dari data pelatihan.
- Data validasi dan pengujian tidak digunakan dalam proses pelatihan maupun pemilihan hyperparameter.

Dengan skema pembagian temporal ini, model dilatih sesuai dengan kondisi operasional nowcasting yang sesungguhnya, di mana prediksi satu jam ke depan hanya dapat dibuat berdasarkan informasi observasi hingga waktu saat ini. Pendekatan ini meningkatkan reliabilitas evaluasi dan mendekatkan hasil penelitian dengan aplikasi nyata di lapangan untuk mitigasi risiko hipotermia pendaki di Gunung Gede–Pangrango.

3.3.4 Pembentukan Fitur dan Representasi Graf

Setelah dataset melalui tahap preprocessing dan pembagian temporal, langkah selanjutnya adalah membentuk representasi data yang sesuai dengan arsitektur model Retrieval-Augmented Diffusion dengan Spatio-Temporal Graph Conditioning. Pada tahap ini, data tidak lagi diperlakukan sebagai tabel konvensional, melainkan direpresentasikan sebagai urutan graf (graph sequence) yang mengintegrasikan informasi spasial dan temporal secara simultan. Proses ini mencakup pembentukan fitur input, pembuatan jendela waktu, serta konstruksi struktur graf yang merepresentasikan hubungan antar node observasi [5], [30].

3.3.4.1 Pembentukan Fitur Input

Fitur input dipilih berdasarkan ketersediaan pada ERA5 dan relevansinya terhadap dinamika presipitasi orografis serta mitigasi risiko hipotermia. Fitur dibedakan menjadi dua kelompok: fitur dinamis (berubah terhadap waktu) dan fitur statis (nilai tetap). Elevasi berfungsi sebagai fitur statis yang memberikan informasi topografi pada setiap node.

Tabel 3.3 Daftar Fitur Input Model

No	Variabel	Keterangan
1	Temperature 2m	Suhu udara
2	Relative Humidity 2m	Kelembapan relatif
3	Dew Point 2m	Titik embun
4	Surface Pressure	Tekanan permukaan

No	Variabel	Keterangan
5	Wind Speed 10m	Kecepatan angin
6	Wind Direction 10m	Arah angin
7	Cloud Cover	Tutupan awan
8	Precipitation Lag-1	Curah hujan 1 jam sebelumnya
9	Elevation	Ketinggian node

Secara matematis, vektor fitur untuk node ke- n pada waktu t dapat dituliskan sebagai:

3.3.4.2 Pembentukan Jendela Waktu (*Temporal Window*)

Untuk menangkap ketergantungan temporal, data disusun menggunakan pendekatan sliding window. Setiap sampel input terdiri dari beberapa observasi historis sebagai konteks prediksi satu jam ke depan. Jendela observasi dapat dinyatakan sebagai:

$$X_t = \{x_{t-L+1}, x_{t-L+2}, \dots, x_t\} \quad (3.4)$$

Dengan:

- X_t = jendela observasi pada waktu t
- L = panjang jendela historis
- x_t = vektor fitur pada waktu t

Melalui pendekatan ini, model dapat mempelajari perubahan kondisi atmosfer yang terjadi dalam beberapa jam sebelumnya sebelum menghasilkan prediksi pada waktu berikutnya.

3.3.4.3 Representasi Graf Spasial

Hubungan spasial antar titik pengamatan direpresentasikan dalam bentuk graf. Penelitian ini menggunakan lima node dengan node MAIN sebagai target prediksi utama, sedangkan node UP, DOWN, LEFT, dan RIGHT berfungsi sebagai konteks spasial multidirectional. Struktur graf menggunakan topologi star dengan delapan edge terarah: MAIN↔UP, MAIN↔DOWN, MAIN↔LEFT, dan MAIN↔RIGHT. Node tetangga tidak memiliki edge langsung satu sama lain.

3.3.4.4 Representasi Spasio-Temporal

Setelah struktur graf terbentuk, informasi spasial dan temporal digabungkan menjadi rangkaian graf (*graph sequence*). Pada setiap langkah waktu digunakan struktur graf yang sama, sedangkan nilai fitur pada masing-masing node diperbarui sesuai kondisi meteorologis aktual. Secara konseptual, rangkaian graf dapat dituliskan sebagai:

$$g = \{G_{t-L+1}, G_{t-L+2}, \dots, G_t\} \quad (3.5)$$

dengan:

- G_t = graf pada waktu t
- g = urutan graf yang menjadi input model

Melalui tahap pembentukan fitur dan representasi graf ini, data berhasil diubah menjadi format yang sesuai dengan kebutuhan Graph Neural Network dan conditional diffusion model. Representasi spasio-temporal yang dihasilkan memungkinkan model mempelajari baik ketergantungan antar lokasi maupun evolusi kondisi atmosfer dari waktu ke waktu, sehingga mendukung prediksi probabilistik yang lebih akurat untuk mitigasi risiko hipotermia di Gunung Gede–Pangrango [5], [30], [17].

3.3.5 Perancangan Arsitektur Model

Arsitektur model yang dikembangkan dalam penelitian ini merupakan integrasi antara tiga komponen utama, yaitu Spatio-Temporal Graph Neural Network (STGNN), Retrieval-Augmented Mechanism, dan Conditional Diffusion Model. Desain ini dirancang khusus untuk menangani karakteristik presipitasi orografis di pegunungan tropis serta menghasilkan prediksi probabilistik satu jam ke depan yang akurat dan sensitif terhadap kejadian ekstrem [27], [5], [30].

3.3.5.1 Spatio-Temporal Graph Neural Network (STGNN)

Komponen pertama adalah Spatio-Temporal Graph Neural Network yang bertugas mengekstraksi fitur spasial dan temporal dari kelima node observasi. Pada setiap timestep, Graph Attention Network (GAT) digunakan untuk memproses struktur graf dan mempelajari bobot hubungan antar node secara adaptif. Proses encoding spasial dapat dinyatakan dengan:

$$h_\tau = GAT(G_\tau) \quad (3.6)$$

dengan:

- G_τ = graf pada waktu τ
- h_τ = representasi spasial hasil encoding

Representasi dari seluruh timestep dalam jendela historis kemudian diagregasi menggunakan mekanisme temporal attention untuk menghasilkan representasi spasio-temporal akhir:

$$h_t^G = \text{TemporalAttention}(h_{t-L+1}, \dots, h_t) \quad (3.7)$$

dengan:

- h_t^G = representasi spasio-temporal akhir pada waktu t
- L = panjang jendela observasi historis

Komponen STGNN memungkinkan model memahami bagaimana kondisi di node UP, DOWN, LEFT, dan RIGHT memengaruhi node MAIN [5], [30].

3.3.5.2 Retrieval-Augmented

Untuk meningkatkan kemampuan model dalam menangani kejadian ekstrem, mekanisme retrieval historical analogs digunakan. Komponen ini mencari kondisi historis yang paling mirip dengan kondisi saat ini dari basis data pelatihan. Proses retrieval dapat diformulasikan sebagai:

$$R_t = kNN(c_t, D_{train}, k) \quad (3.8)$$

dengan:

- c_t = representasi kondisi atmosfer saat ini
- D_{train} = basis data historis dari data pelatihan
- k = jumlah analog historis yang diambil
- R_t = himpunan analog historis yang ditemukan

Mekanisme ini sangat penting untuk mengatasi data scarcity pada presipitasi ekstrem di wilayah pegunungan tropis [27], [17].

3.3.5.3 Conditional Diffusion Model

Komponen inti model adalah Conditional Diffusion Model yang bertugas menghasilkan distribusi prediksi probabilistik. Model ini mempelajari proses forward diffusion (penambahan noise) dan reverse diffusion (penghilangan noise) secara kondisional. Persamaan forward diffusion adalah:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon \quad (3.9)$$

dengan:

- x_0 = data asli
- x_t = data setelah penambahan noise pada timestep t
- ϵ = noise Gaussian

Model kemudian dilatih untuk memprediksi noise tersebut dengan kondisi tambahan dari STGNN dan retrieval:

$$\hat{\epsilon}_\theta = f_\theta(x_t, t, h_t^G, R_t) \quad (3.10)$$

dengan:

- $\hat{\epsilon}_\theta$ = prediksi noise oleh model
- h_t^G = representasi dari STGNN
- R_t = hasil retrieval

3.3.5.4 Integrasi Antar Komponen Model

Ketiga komponen bekerja secara terintegrasi. Representasi dari STGNN dan hasil retrieval menjadi conditioning input bagi diffusion model, sehingga prediksi yang dihasilkan tidak hanya probabilistik tetapi juga kontekstual terhadap dinamika spasial dan historis di kawasan Gunung Gede–Pangrango. Pendekatan ini memungkinkan model mempelajari distribusi kondisional berikut:

$$p(y_{t+1}^{MAIN} | X_t) \quad (3.11)$$

dengan:

- y_{t+1}^{MAIN} = prediksi pada node MAIN
- X_t = jendela observasi historis

Dengan arsitektur yang terintegrasi ini, model menghasilkan sampel prediksi probabilistik untuk dievaluasi dari sisi akurasi titik, kualitas distribusi, dan deteksi kejadian hujan.

3.3.6 Prosedur Pelatihan Model

Setelah arsitektur model dirancang, tahap pelatihan dilakukan untuk mengoptimalkan parameter model agar mampu mempelajari pola kompleks dari data spasio-temporal serta menghasilkan prediksi probabilistik yang akurat. Proses pelatihan menggunakan data pelatihan yang telah melalui preprocessing dan representasi graf, dengan tujuan utama meminimalkan kesalahan prediksi sekaligus meningkatkan sensitivitas terhadap kejadian ekstrem yang berpotensi memicu hipotermia pendaki [5], [27].

Proses pelatihan diawali dengan pembentukan sampel berupa graph sequence dari jendela historis. Setiap sampel input terdiri dari observasi selama beberapa timestep sebelumnya beserta struktur graf lima node, dengan node MAIN sebagai target prediksi. Model kemudian melakukan *forward pass* yang meliputi ekstraksi representasi oleh STGNN, pencarian analog historis melalui retrieval mechanism, dan prediksi noise pada Conditional Diffusion Model.

Optimasi parameter dilakukan menggunakan algoritma AdamW dengan mekanisme backpropagation dan weight decay $1e-4$. Parameter normalisasi dan basis retrieval hanya dihitung dari data pelatihan untuk mencegah data leakage. Pada akhir setiap epoch, model dievaluasi menggunakan data validasi. Model dengan performa validasi terbaik (berdasarkan loss dan metrik lain) disimpan sebagai model akhir yang akan digunakan pada tahap inferensi.

Weighted denoising loss memberikan bobot 5 kali untuk target ternormalisasi dengan nilai absolut lebih dari 1,0 dan 10 kali untuk nilai absolut lebih dari 3,0. Pembobotan ini meningkatkan penekanan pada target besar, tetapi tidak mengatasi kelangkaan informasi kejadian ekstrem dalam data. Dengan auxiliary task wet/dry dan pemilihan model berdasarkan validasi, proses pelatihan ditujukan untuk meningkatkan sensitivitas terhadap kejadian berisiko tinggi [27], [5], [17].

3.3.7 Prosedur Inferensi

Setelah model terbaik diperoleh dari tahap pelatihan, proses inferensi dilakukan untuk menghasilkan prediksi probabilistik satu jam ke depan. Pada tahap ini, model menerima data observasi terbaru sebagai input dan menghasilkan distribusi prediksi untuk variabel target (curah hujan, kecepatan angin, dan kelembapan relatif) pada node MAIN. Prosedur inferensi mengikuti pendekatan *one-step rolling forecasting* yang sesuai dengan kondisi operasional nowcasting di lapangan [4], [5], [27].

Proses inferensi dimulai dengan pembentukan jendela observasi historis (*historical context window*). Data dari lima node disusun dalam urutan tetap [MAIN, UP, DOWN, LEFT, RIGHT] selama beberapa timestep sebelumnya. Jendela observasi ini dapat dinyatakan sebagai:

$$X_t = \{G_{t-L+1}, G_{t-L+2}, \dots, G_t\} \quad (3.12)$$

Dengan:

- X_t = jendela observasi pada waktu t
- G_t = graf pada waktu t
- L = panjang jendela historis

Jendela ini kemudian diproses oleh Spatio-Temporal Graph Neural Network (STGNN) untuk menghasilkan representasi konteks spasial dan temporal. Selanjutnya dilakukan retrieval historical analogs untuk mencari kondisi historis yang paling mirip dengan kondisi saat ini. Representasi dari STGNN dan hasil retrieval kemudian dijadikan kondisi tambahan pada Conditional Diffusion Model. Proses reverse diffusion dilakukan untuk menghasilkan ensemble prediksi melalui sampling berulang dengan inisialisasi noise yang berbeda.

Hasil prediksi kemudian dikembalikan ke skala asli menggunakan transformasi invers logaritmik untuk variabel curah hujan. Selain itu, output dari *wet/dry auxiliary head* digunakan sebagai *rain gate* untuk menyaring prediksi hujan palsu.

Prosedur inferensi ini dirancang agar sesuai dengan kondisi operasional nyata, di mana prediksi selalu dibuat berdasarkan data observasi terkini tanpa akses ke informasi masa depan. Dengan pendekatan ini, model mampu menghasilkan prediksi probabilistik yang andal dan dapat digunakan langsung untuk mendukung sistem peringatan dini mitigasi risiko hipotermia pendaki di Gunung Gede–Pangrango [27], [5], [17].

3.3.8 Metode Evaluasi Model

Evaluasi model dilakukan untuk mengukur kemampuan sistem dalam memprediksi kondisi meteorologis pada node utama (MAIN) secara akurat dan andal. Mengingat model menghasilkan prediksi dalam bentuk distribusi probabilistik, evaluasi tidak hanya mencakup akurasi titik (point forecast), tetapi juga kualitas distribusi probabilitas dan kemampuan deteksi kejadian ekstrem. Seluruh evaluasi dilakukan secara eksklusif menggunakan data pengujian (test set) yang tidak pernah digunakan selama pelatihan maupun pemilihan model [4], [5], [27].

Evaluasi model dibagi menjadi tiga kelompok utama: evaluasi deterministik, evaluasi probabilistik, dan evaluasi berbasis kejadian. Selain itu, dilakukan pula analisis reliabilitas distribusi prediksi.

a. Evaluasi Deterministik

Evaluasi deterministik mengukur kedekatan antara prediksi titik (median dari ensemble) dengan nilai observasi aktual. Metrik yang digunakan meliputi:

1. Mean Absolute Error (MAE)
2. Root Mean Square Error (RMSE)
3. Pearson Correlation Coefficient (r)

b. Evaluasi Probabilistik

Evaluasi probabilistik menilai kualitas distribusi prediksi yang dihasilkan oleh diffusion model.

1. Continuous Ranked Probability Score (CRPS)
2. Brier Score

c. Evaluasi Berbasis Kejadian Hujan

Evaluasi ini menilai kemampuan model mendeteksi kejadian hujan pada berbagai tingkat intensitas (ambang 2 mm, 5 mm, dan 10 mm). Metrik yang digunakan adalah:

1. Probability of Detection (POD): Proporsi kejadian hujan yang berhasil dideteksi.
2. False Alarm Ratio (FAR): Proporsi alarm palsu.
3. Critical Success Index (CSI): Ukuran keseluruhan keberhasilan deteksi.

d. Evaluasi Reliabilitas Prediksi

Reliabilitas dinilai menggunakan *Reliability Diagram* yang membandingkan probabilitas prediksi dengan frekuensi kejadian aktual. Diagram ini menunjukkan sejauh mana probabilitas yang dihasilkan model sesuai dengan realisasi observasi di lapangan.

Tabel 3.4 Ringkasan Metrik Evaluasi

Kelompok Evaluasi	Metrik Utama	Tujuan Utama
Deterministik	MAE, RMSE, Pearson Correlation	Akurasi prediksi titik
Probabilistik	CRPS, Brier Score	Kualitas distribusi probabilitas

Kelompok Evaluasi	Metrik Utama	Tujuan Utama
Berbasis Kejadian	POD, FAR, CSI	Kemampuan deteksi kejadian hujan
Reliabilitas	Reliability Diagram	Kalibrasi probabilitas

Evaluasi dilakukan dengan pendekatan one-step rolling forecast pada data pengujian. Model menggunakan enam jam observasi terakhir untuk memprediksi satu jam berikutnya ($t + 1$). Untuk hasil utama, titik evaluasi diambil setiap 11 jam, parameter ini hanya mengatur jarak antar sampel evaluasi untuk mengurangi bias akibat autokorelasi, bukan horizon prediksi. Evaluasi penuh setiap jam tetap didukung melalui `eval\_step=1`. Seluruh skenario menggunakan titik evaluasi yang sama. Dalam penggunaan operasional, apabila sumber data near real-time tersedia, model dapat dijalankan setiap jam dengan rolling window enam jam terakhir.

Dengan metode evaluasi yang komprehensif ini, penelitian dapat memberikan gambaran yang lengkap mengenai performa model, baik dari sisi akurasi, kalibrasi probabilitas, maupun kemampuan deteksi kejadian ekstrem yang relevan dengan mitigasi risiko hipotermia pendaki di Gunung Gede–Pangrango [4], [5], [27], [29].

3.3.9 Skenario Eksperimen

Skenario eksperimen dirancang untuk mengevaluasi secara sistematis kontribusi masing-masing komponen dalam arsitektur model yang diusulkan. Evaluasi tidak hanya dilakukan terhadap model akhir, tetapi juga terhadap beberapa konfigurasi bertahap. Pendekatan ini memungkinkan identifikasi pengaruh setiap komponen (STGNN, Retrieval-Augmented Mechanism, dan Conditional Diffusion Model) terhadap peningkatan performa prediksi [5], [27], [30].

Seluruh skenario dijalankan menggunakan data pengujian yang sama dan mengikuti prosedur inferensi one-step rolling forecasting yang telah dijelaskan sebelumnya. Tujuan utama eksperimen adalah (1) membandingkan model yang diusulkan dengan baseline, (2) mengukur kontribusi masing-masing komponen, dan (3) menilai efektivitas integrasi keseluruhan komponen dalam mendukung nowcasting probabilistik untuk mitigasi risiko hipotermia. Enam skenario eksperimen yang dijalankan adalah sebagai berikut:

1. **Persistence** Baseline paling sederhana yang mengasumsikan nilai pada waktu $t + 1$ sama dengan nilai observasi pada waktu t . Digunakan untuk menilai seberapa besar peningkatan yang diperoleh dibandingkan metode naif.
2. **Multi-Layer Perceptron (MLP Baseline)** Model deterministik berbasis neural network yang hanya menggunakan fitur historis dari node MAIN. Skenario ini memberikan pembandingan terhadap metode yang lebih kompleks tanpa memanfaatkan informasi spasial maupun historis tambahan [14], [15].
3. **Diffusion Model Only** Conditional Diffusion Model tanpa STGNN dan retrieval. Skenario ini mengevaluasi kontribusi dasar dari pendekatan diffusion probabilistik.
4. **Diffusion dan Retrieval** Diffusion Model yang dilengkapi mekanisme retrieval historical analogs. Skenario ini mengukur manfaat penambahan konteks historis terhadap kualitas distribusi prediksi [27], [30].
5. **Diffusion dan STGNN** Diffusion Model yang terintegrasi dengan Spatio-Temporal Graph Neural Network. Skenario ini menilai kontribusi representasi spasial multidirectional dari lima node observasi [5], [17].
6. **Full Model (Diffusion, Retrieval, dan STGNN)** Konfigurasi lengkap yang merupakan model utama yang diusulkan. Skenario ini mengevaluasi sinergi keseluruhan komponen.

Perbandingan antar skenario dilakukan menggunakan seluruh metrik evaluasi yang telah dijelaskan pada subbab sebelumnya (MAE, RMSE, Pearson Correlation, CRPS, Brier Score, POD, FAR, CSI, serta Reliability Diagram). Dengan menggunakan metrik yang sama, peningkatan performa dapat dikaitkan langsung dengan penambahan komponen tertentu.

Hasil eksperimen disajikan dalam bentuk tabel perbandingan metrik, grafik visualisasi prediksi versus observasi, reliability diagram, serta analisis kontribusi komponen (*ablation study*). Pendekatan ini memungkinkan penelitian tidak hanya menunjukkan bahwa model yang diusulkan lebih baik, tetapi juga menjelaskan *mengapa* dan *komponen mana* yang memberikan kontribusi paling signifikan.

Melalui skenario eksperimen yang terstruktur ini, penelitian membandingkan kontribusi Retrieval-Augmented Diffusion Model dengan Spatio-Temporal Graph

Conditioning terhadap baseline dalam konteks nowcasting presipitasi di Gunung Gede–Pangrango [27], [5], [30].

DAFTAR PUSTAKA

- [1] D. Luciano and D. L. Giovanna, “Rainfall nowcasting model for early warning systems applied to a case over Central Italy,” *Nat. Hazards*, vol. 112, no. 1, pp. 501–520, 2022, doi: 10.1007/s11069-021-05191-w.
- [2] P. Chavula, F. Kayusi, G. Lungu, and A. Uwimbabazi, “The Current Landscape of Early Warning Systems and Traditional Approaches to Disaster Detection,” 2025, doi: 10.62486/latia202577.
- [3] M. Reichstein *et al.*, “Early warning of complex climate risk with integrated artificial intelligence,” *Nat. Commun.*, no. May 2024, 2025, doi: 10.1038/s41467-025-57640-w.
- [4] S. Ravuri *et al.*, “Skilful precipitation nowcasting using deep generative models of radar,” *Nature*, vol. 597, no. February, 2021, doi: 10.1038/s41586-021-03854-z.
- [5] Y. Zhang, M. Long, K. Chen, L. Xing, and R. Jin, “Skilful nowcasting of extreme precipitation with NowcastNet,” vol. 619, no. September 2022, 2023, doi: 10.1038/s41586-023-06184-4.
- [6] A. Mazza, A. Antonini, S. Melani, and A. Ortolani, “A Radar-Based Fast Code for Rainfall Nowcasting over the Tuscany Region,” pp. 1–24, 2025.
- [7] A. P. Lakspriyanti, M. Ekayani, and A. Sunkar, “CARRYING CAPACITY ASSESSMENT OF CIBEUREUM WATERFALL TOURISM IN GUNUNG GEDE PANGRANGO NATIONAL PARK,” vol. 25, no. 3, pp. 203–211, 2020, doi: 10.29244/medkon.25.3.203-211.
- [8] D. Sun, J. Wu, H. Huang, R. Wang, F. Liang, and H. Xinhua, “Prediction of Short-Time Rainfall Based on Deep Learning,” vol. 2021, 2021, doi: 10.1155/2021/6664413.
- [9] Q. Nicolas and W. R. Boos, “Understanding the Spatiotemporal Variability of Tropical Orographic Rainfall Using Convective Plume Buoyancy,” pp. 1737–1757, 2024, doi: 10.1175/JCLI-D-23-0340.1.
- [10] C. L. Tsai, G. Lee, K. Kim, H. Park, H. Park, and W. Bang, “Association Between Upstream Conditions and the Intensity of Orographic Precipitation in the Main Mountain Ranges of South Korea,” 2025, doi: 10.1029/2024EA003989.

- [11] L. Silva, R. Céleri, and M. Córdova, “Diurnal to seasonal meteorological cycles along an equatorial Andean elevational gradient,” vol. 48, pp. 33–48, 2025.
- [12] X. Zhang, M. Xu, S. Kang, H. Wu, and H. Han, “The spatiotemporal variability in precipitation gradients based on meteorological station observations in mountainous areas of Northwest China,” 2023.
- [13] Y. Jiang *et al.*, “Characterizing basin-scale precipitation gradients in the Third Pole region using a high-resolution atmospheric simulation-based dataset,” pp. 4587–4601, 2022.
- [14] M. Bonavita, “On Some Limitations of Current Machine Learning Weather Prediction Models,” 2024, doi: 10.1029/2023GL107377.
- [15] Z. Ben Bouallègue *et al.*, “The Rise of Data-Driven Weather Forecasting: A First Statistical Assessment of Machine Learning–Based Weather Forecasts in an Operational-Like Context,” pp. 864–883, 2024, doi: 10.1175/BAMS-D-23-0162.1.
- [16] X. Zhong *et al.*, “FuXi-ENS : A machine learning model for efficient and accurate ensemble weather prediction,” pp. 1–14, 2025, doi: 10.1126/sciadv.adu2854.
- [17] I. Price *et al.*, “Probabilistic weather forecasting with machine learning,” *Nature*, vol. 637, no. April 2024, pp. 8–11, 2025, doi: 10.1038/s41586-024-08252-9.
- [18] O. A. Wani *et al.*, “Predicting rainfall using machine learning , deep learning , and time series models across an altitudinal gradient in the North-Western Himalayas,” 2024.
- [19] L. He *et al.*, “Deep Learning-Based Feature Importance for Rainfall Nowcast Driven by GNSS,” *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.*, vol. 18, pp. 26688–26698, 2025, doi: 10.1109/JSTARS.2025.3621857.
- [20] H. Kim, S. Yoon, Y. H. Gu, S. H. Kim, and Y. Choi, “A Hybrid Approach to Physical and Deep Learning Models for Radar-Based Precipitation Nowcasting,” *IEEE Trans. Geosci. Remote Sens.*, vol. 63, pp. 1–16, 2025, doi: 10.1109/TGRS.2025.3560454.

- [21] Z. Zhang, Q. Song, M. Duan, H. Liu, and J. Huo, "Deep Learning Model for Precipitation Nowcasting Based on Residual and Attention Mechanisms," pp. 1–17, 2025.
- [22] J. H. Meltzer and J. D. Forrester, "Human-Factor Risk Mitigation in Outdoor Climbing Areas : Survey of Existing Policies in Regulated Climbing Areas," vol. 32, no. 4, 2021, doi: 10.1016/j.wem.2021.08.001.
- [23] E. Rahmah, E. K. S. H. Muntasib, and S. B. Rushayati, "Tourism Hazard Mitigation in Mount Rinjani National Park ," vol. 2, no. 2, pp. 5–19, 2021, doi: 10.22158/sshsr.v2n2p5.
- [24] K. Hanly and G. Mcdowell, "The Evolution of ‘ Risksapes ’: 100 years of climate change and mountaineering activity in the Lake Louise area of the Canadian Rockies," pp. 1–25, 2023.
- [25] P. M. Zarinabegam, I. Kale, P. Deshmukh, and A. Khilare, "IOT-Based Advanced Monitoring System for Outdoor Safety," no. May, 2025, doi: 10.22214/ijraset.2025.70379.
- [26] G. Ayzel and M. Heistermann, "Brief communication : Training of AI-based nowcasting models for rainfall early warning should take into account user requirements," pp. 41–47, 2025.
- [27] A. Asperti, F. Merizzi, A. Paparella, and G. Pedrazzi, "Precipitation nowcasting with generative diffusion models," *Appl. Intell.*, 2024, doi: <https://doi.org/10.1007/s10489-024-06048-y>.
- [28] E. Procter, H. Brugger, and M. Burtcher, "Accidental hypothermia in recreational activities in the mountains : A narrative review," no. August, pp. 2464–2472, 2018, doi: 10.1111/sms.13294.
- [29] S. P. Ashok and S. Pekkat, "A systematic quantitative review on the performance of some of the recent short-term rainfall forecasting techniques," *J. Water Clim. Chang.*, vol. 13, no. 8, 2022, doi: 10.2166/wcc.2022.302.
- [30] S. Haji-aghajany, W. Rohm, P. Lipinski, and M. Kryza, "Beyond the horizon : A comprehensive analysis of artificial intelligence-based weather forecasting models," *Eng. Appl. Artif. Intell.*, vol. 162, no. PA, p. 112335, 2025, doi: 10.1016/j.engappai.2025.112335.

- [31] M. Dumont, M. Saadi, L. Oudin, P. Lachassagne, B. Nugraha, and A. Fadillah, "Assessing rainfall global products reliability for water resource management in a tropical volcanic mountainous catchment," *J. Hydrol. Reg. Stud.*, vol. 40, no. February, 2022, doi: 10.1016/j.ejrh.2022.101037.
- [32] Q. Nicolas and W. R. Boos, "Sensitivity of tropical orographic precipitation to wind speed with implications for future projections," pp. 231–244, 2025.
- [33] E. Yulihastin, T. W. Hadi, N. S. Ningsih, and M. R. Syahputra, "Early morning peaks in the diurnal cycle of precipitation over the northern coast of West Java and possible influencing factors," pp. 231–242, 2020.